Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Maestría en Inteligencia Artificial

Sistema RAG conversacional Embebido en un entorno 3D para interacción inteligente.

Trabajo de innovación presentado por:	Vélez Cortés Eduardo Arturo Eynar Adrián Gutiérrez Pabon Montero Marín Mauricio Hernández Gajardo Rodrigo Rico Hernández Julio Alberto
Fecha:	15/Abril/2026

Índice de contenidos

1. Introducción 6
Justificación del Trabajo 7
¿Cuál es el problema que quieres tratar? 7
¿Cuáles crees que son las causas? 7
¿Por qué es relevante el problema? 8
Estructura en secciones 8
2. Objetivos 9
Objetivo general 9
Objetivos específicos 9
Enfoque de impacto esperado 9
3. Desarrollo conceptual 10
Empatizar 10
Definir 12
Investigación de antecedentes 13
1. Limitaciones de los NPCs con diálogos preestablecidos 13
2. RAG como mecanismo de coherencia y control narrativo 14
3. Consideraciones de latencia en la inferencia del LLM 15
Idear 16
Prototipar 16
Objetivo del prototipo 16
Alcance del prototipo 17
Descripción del prototipo frontend 17

Justificación del prototipo dentro de Design Thinking 18
Muestra del prototipo 19
Prototipo del Backend 24
Prototipo Backend RAG con NPC 25
Descripción General 25
Pipeline de Ingesta de Información (Administrador) 25
Pipeline de Consulta (Usuario Final vía NPC) 25
Integración del NPC con el Backend 26
Valor del Prototipo 26
Conclusión 26
Selección de prototipos y criterio para hacerlo 26
Criterios utilizados para la selección de prototipos 27
Justificación de la selección dual (Frontend + Backend) 29
Resultado esperado de la selección de prototipos 29
Síntesis 29
4. Metodologías Ágiles 30
Justificación metodológica 34
Configuración del proyecto en Jira 34
Criterio de Estimación: Planning Poker 36
Secuencia del Proceso 37
Reflexión Crítica 40
Producto Mínimo Víable (MVP) 45
5. Implementación de la propuesta 47
5.1 Planificación y estimación 47
5.2 Implementación 47

Arquitectura del Sistema 47
5.3 Despliegue 48
Sistema backend 49
Problema que resuelve 49
Componentes prioncipales 49
1. API REST (FastAPI) 49
2. Pipeline de Inyección (Procesamiento de PDFs) 50
3. Base de Datos 50
SQLite/PostgreSQL (Metadata) 50
Qdrant (Vector Store) 50
Redis (Caché) 50
4. Motor de Búsqueda Semántica 51
5. LLM Service (Groq API) 51
Prompt Template (Instancia RAG) 51
6. Gestión de Sesiones 52
Ciclo de vida: 52
Arquitectura del sistema backend 53
5.4 Mantenimiento 53
6. Validación y diseño experimental 54
6.1 Definición del MVP 54
6.2 Evolución del prototipo al MVP 54
6.3 MVP Evaluación del RAG al back-end 55
6.3.1 Métricas de Generación 55
6.3.2 Métricas de Recuperación (Contexto) 55
6.3.3 Métricas de Resultado Final 56

6.3.4 Métricas Principales 56

Implementación de Juez Evaluador 58

Fase de entrada 58

Fase de evaluación 58

Resumen del análisis de métricas cuantitativas 61

6.4 Entorno tridimensional final 61

6.5 Sistema de interacción con el NPC 63

6.6 Fase de activación y detección 63

6.7 Fase Conversacional e interfaz gráfica 64

6.8 Integración frontend-backend: flujo de comunicación con el sistema RAG 65

6.9 Consideraciones de diseño de experiencia de usuario 66

6.10 Ciclo de Construir-Medir-Aprender (Lean Startup) 67

6.11 Medir Criterios de validación final 67

6.12 Diseño de la sesión de validación 68

7.Conclusiones y trabajo futuro 69

7.1 Resumen del resultado 69

7.2 Limitaciones identificadas 69

7.3 Trabajo futuro 69

7.4 Reflexión final 70

Referencias 70

1. Introducción

A pesar de los avances en inteligencia artificial y simulación 3D, la mayoría de los personajes no jugables (NPCs) en videojuegos, simuladores y entornos de capacitación continúan basándose en diálogos predefinidos y comportamientos rígidos, lo que limita su capacidad de interacción natural, adaptación contextual y transmisión efectiva de conocimiento. Esta limitación reduce significativamente el nivel de inmersión y aprendizaje, especialmente en escenarios donde la comprensión situacional, la toma de decisiones y la interacción fluida con agentes virtuales son elementos críticos, como en la capacitación industrial, técnica o educativa. Estudios recientes señalan que, aunque los modelos de lenguaje de gran escala y los agentes conversacionales han demostrado mejoras sustanciales en la interacción humano-máquina, su integración efectiva dentro de entornos tridimensionales interactivos sigue siendo limitada y poco explorada.

Adicionalmente, los sistemas de inteligencia artificial generativa que incorporan conocimiento específico mediante enfoques como Retrieval-Augmented Generation (RAG) han mostrado un alto potencial para mejorar la precisión, pertinencia y confiabilidad de las respuestas en contextos especializados. Sin embargo, estas arquitecturas rara vez se implementan como entidades embebidas dentro de simulaciones 3D, desaprovechando su capacidad para actuar como agentes inteligentes contextualizados. Esta brecha tecnológica impide el desarrollo de simuladores verdaderamente interactivos y adaptativos, capaces de apoyar tanto experiencias lúdicas avanzadas como sistemas de capacitación inmersiva en múltiples industrias. Por ello, existe una necesidad clara de soluciones que integren IA conversacional contextual con entornos 3D, permitiendo interacciones más naturales, efectivas y orientadas al aprendizaje significativo.

Justificación del Trabajo

¿Cuál es el problema que quieres tratar?

El objetivo de la innovación es **desarrollar un sistema de inteligencia artificial conversacional contextual, basado en Retrieval-Augmented Generation (RAG), embebido en un entorno 3D interactivo**, donde la IA se manifiesta como un personaje no jugable (NPC) capaz de dialogar de forma natural con el usuario. El proyecto pretende solventar la limitación existente en la mayoría de los entornos virtuales, videojuegos y simuladores de capacitación, donde los NPCs dependen de diálogos rígidos y comportamientos predefinidos que reducen la inmersión, la adaptabilidad y la efectividad del aprendizaje. La propuesta busca transformar la interacción usuario-sistema, pasando de interfaces planas y pasivas a **interacciones situadas, naturales y contextuales** dentro de mundos simulados.

¿Cuáles crees que son las causas?

Los modelos actuales de personajes no jugables están diseñados con sistemas basados en árboles de decisión o scripts predefinidos, lo que limita su capacidad para responder dinámicamente a situaciones inesperadas o personalizadas.

Aunque los modelos de lenguaje avanzado y las herramientas de inteligencia artificial han progresado, su incorporación en entornos tridimensionales interactivos sigue estando poco explorada por su complejidad técnica por lo que falta de integración entre IA y simulación 3D interactiva.

Las técnicas de Retrieval-Augmented Generation aún no están completamente optimizadas para manejar el procesamiento y actualización de información contextual en tiempo real al interactuar con simuladores tridimensionales.

Muchas simulaciones y videojuegos priorizan la mecánica del sistema o los gráficos sobre el desarrollo de interacciones naturales, resultando en NPCs que no ofrecen experiencias enriquecedoras de diálogo o interacción.

¿**Por qué es relevante el problema?**

Resolver este problema permitirá que los NPCs se conviertan en agentes inteligentes capaces de enriquecer las experiencias virtuales al dialogar de forma adaptativa y natural con los usuarios.

En industrias como la educación, la formación técnica o la capacitación industrial, la interacción con NPCs avanzados en entornos 3D podría simular situaciones del mundo real, mejorando la comprensión, toma de decisiones y retención de conocimiento.

Un cambio hacia NPCs inteligentes y contextualmente adaptados podría revolucionar el diseño de juegos, ofreciendo experiencias más dinámicas, lúdicas y complejas.

La integración de tecnologías como RAG e IA generativa contextual con entornos tridimensionales llenará una brecha existente en el desarrollo de sistemas que combinen alta adaptabilidad y fluidez interactiva.

Estructura en secciones

El trabajo se organiza de forma progresiva, iniciando con una introducción que expone la problemática de los NPCs tradicionales en entornos 3D, sus limitaciones y la relevancia de integrar inteligencia artificial conversacional contextual basada en RAG; posteriormente se presentan los objetivos generales y específicos del proyecto, seguidos por el desarrollo conceptual sustentado en la metodología de Design Thinking, que incluye el análisis de necesidades de los usuarios, la investigación de antecedentes y el estado del arte sobre arquitecturas LLM en entornos XR; a continuación se describe el diseño e implementación del prototipo, tanto del entorno 3D como del backend RAG, junto con sus flujos de interacción; seguidamente se aborda la selección de prototipos y los criterios técnicos y de experiencia de usuario utilizados para justificar la estrategia dual adoptada; finalmente se presentan las conclusiones y síntesis de resultados, cerrando con las referencias que respaldan teóricamente la propuesta desarrollada.

2. Objetivos

Objetivo general

Desarrollar una solución funcional como prueba de concepto que integre inteligencia artificial conversacional contextual basada en Retrieval-Augmented Generation (RAG) dentro de un entorno tridimensional interactivo, permitiendo que un personaje no jugable (NPC) actúe como agente inteligente capaz de ofrecer interacciones naturales, adaptativas y orientadas al aprendizaje, mejorando la inmersión y efectividad de la experiencia del usuario.

Objetivos específicos

Diseñar un entorno 3D interactivo que permita la exploración del usuario y la interacción intuitiva con un NPC, simulando escenarios inmersivos aplicables a videojuegos y contextos de capacitación.

1. Implementar un prototipo backend basado en arquitectura RAG capaz de transformar documentos en conocimiento consultable mediante embeddings y recuperación semántica.
2. Integrar el NPC con el sistema de inteligencia artificial a través de APIs, permitiendo la comunicación en tiempo real entre el entorno 3D y el modelo conversacional.
3. Evaluar la capacidad del sistema para generar respuestas contextuales precisas, relevantes y coherentes frente a preguntas del usuario dentro del entorno virtual.
4. Analizar la experiencia de usuario en términos de inmersión, fluidez de interacción, comprensión del rol del NPC y percepción de utilidad del sistema.
5. Validar la viabilidad técnica de combinar modelos de lenguaje avanzados con simulaciones tridimensionales interactivas en un sistema modular y escalable.
6. Identificar oportunidades de mejora y limitaciones del prototipo para futuras iteraciones y desarrollos más complejos.

Enfoque de impacto esperado

Con el cumplimiento de estos objetivos se busca:

- Transformar la interacción tradicional con NPCs estáticos hacia agentes inteligentes contextuales
- Mejorar procesos de aprendizaje, capacitación y exploración en entornos virtuales
- Demostrar el potencial de la IA conversacional embebida en mundos 3D como nueva interfaz de conocimiento

3. Desarrollo conceptual

Imagen 1 *Proceso de Design Thinking: comprender, definir, idear, prototipar y probar.*

Empatizar

Definición: Comprender las necesidades, expectativas y limitaciones de los usuarios finales dentro del contexto de interacción.

Observación directa

Se observaron 10 individuos en la interacción con videojuegos destacando los siguientes puntos:

1. Los jugadores **más jóvenes leen** los diálogos que aparecen en el juego, pero una vez que ya saben cómo jugar los ignoran.

2. Los jugadores más **experimentados no leen** los diálogos durante el videojuego y están más enfocados a jugar.
3. Cuando hay dudas acerca del videojuego se recurre a **foros**.
4. Los jugadores **suelen utilizar tutoriales** o **guías** en situaciones donde se encuentran estancados en el progreso del juego teniendo una preferencia por la autoexploración inicial.
5. Algunos jugadores mencionaron que los diálogos y la narrativa se vuelven relevantes cuando hay elementos de la historia que impactan la jugabilidad.
6. Se observó que los diálogos con opciones de respuesta que afectan el desarrollo de la historia generan un mayor interés, especialmente en jugadores jóvenes que buscan una experiencia más inmersiva. Existen juegos donde en base a esos diálogos se eligen las misiones a realizar en el juego.
7. Los jugadores tienen a utilizar los chats de los mismos juegos para discutir sus experiencias o utilizar redes sociales.

Necesidades por parte del usuario

1. Respuestas claras y concretas a las preguntas hechas
2. Buenas respuestas para simular conversaciones naturales.
3. Interacción con el sistema sin interrupciones
4. Interacción rápida con el sistema.

Expectativa por parte de los usuarios

Usuario: “Espero que el NPC pueda responder a todas mis preguntas rápidamente y con precisión”.

Usuario: “Quiero respuestas de manera rápida, como si estuviera interactuando con el creador del juego “

Usuario: “No estoy seguro de que sea una opción buena lo que me interesa es jugar, no interactuar con un NPC.”

Usuario: “Que el sistema me de tips para poder ganar”

Limitaciones

- Existirá frustración de parte de los usuarios si las respuestas son genéricas o no son lo que el usuario final espera.
- La Infraestructura es una parte fundamental de esta solución ejemplo conectividad y acceso.
- Recursos del sistema para ofrecer tiempos de respuesta aceptables.

Mapa de empatía

Que siente?

- Algunos usuarios pueden sentir curiosidad por ver como seria el sistema final y en que puede ayudarlos.
- Desinterés debido a que no es algo que necesiten para poder entender un juego.

Que oye?

- Las respuestas del sistema NPC serán frases claras y respuestas específicas.
- Si el sistema no puede dar una respuesta deberemos considerar una respuesta de error como “Lo siento no tengo esa respuesta” o algo así.
- El sistema podría tener un sonido ambiente configurable.

Que ve?

- Un entorno 3D inmersivo, buenos gráficos y detalle haciendo la experiencia más interactiva
- Distintos escenarios dependiendo del propósito

Que dice y hace?

- Preguntas relacionadas con el juego o con el entorno configurado
- Inspeccionar las opciones disponibles en el sistema.

Definir

- **Objetivo**: Enmarcar claramente el problema a resolver en términos de los hallazgos de la etapa anterior.

El sistema necesita NPCs conversacionales adaptativos para promover mayor inmersión, aprendizaje significativo y desempeño en simulaciones 3D.

Se deberá solucionar los diálogos típicos de NPCs, la falta de respuesta adaptativas y personalizadas y la poca base conocimientos especializados en tiempo real.

El objetivo del sistema es transformar la interacción usuario-sistema, permitiendo experiencias naturales, contextuales e inteligentes.

Investigación de antecedentes

1. Limitaciones de los NPCs con diálogos preestablecidos

Los personajes no jugables (NPCs) han dependido históricamente de diálogos preestablecidos y árboles de conversación rígidos que, aunque predecibles y estables, carecen de adaptabilidad y relevancia contextual. Este modelo presenta limitaciones estructurales evidentes: el jugador percibe rápidamente los límites del guion, la repetición rompe la inmersión y cualquier pregunta fuera del árbol predefinido resulta en respuestas genéricas o en silencio. La naturaleza estática de estos sistemas impide que el NPC recuerde interacciones anteriores, adapte su tono al contexto o responda a entradas no anticipadas por el diseñador.

La integración de modelos de lenguaje de gran escala (LLMs) como GPT-4, Claude o LLaMA representa un cambio cualitativo en este paradigma. Estudios comparativos muestran que los agentes conversacionales basados en LLM producen niveles de compromiso e inmersión significativamente superiores a los de sus equivalentes estáticos. En entornos de aprendizaje basado en juegos, Wang et al. (2025) encontraron que los NPCs con LLM generaron mayor fluidez de interacción y menor carga cognitiva que los agentes basados en reglas, resultados que se extienden al entretenimiento puro en tanto que ambos contextos comparten el mismo mecanismo de inmersión: la percepción del jugador de estar frente a un interlocutor genuinamente responsivo.

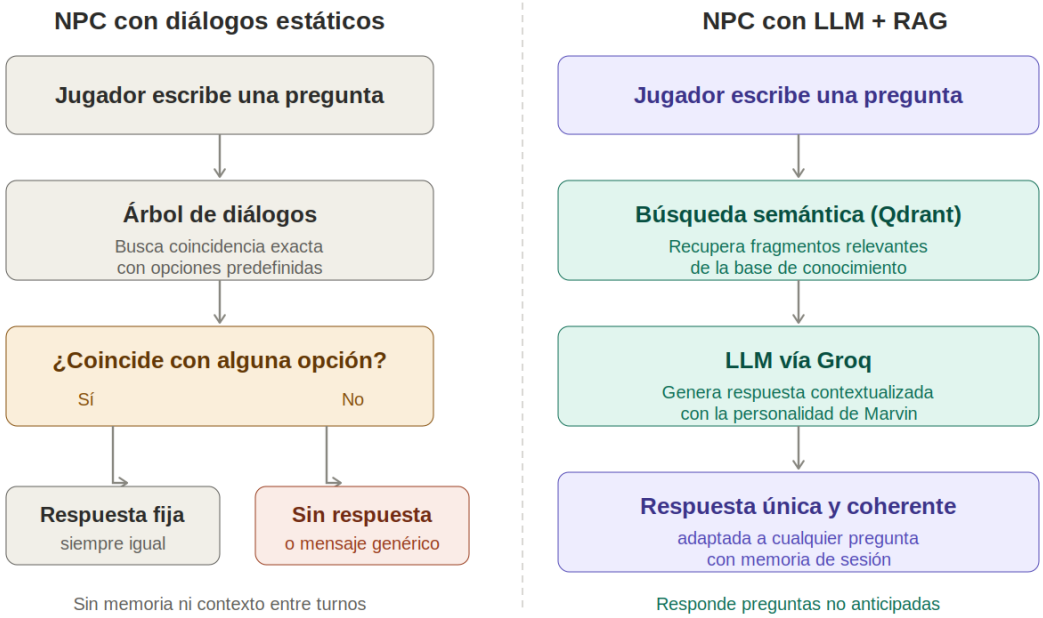

Imagen 2 *NPC tradicional con respuestas fijas vs. NPC con LLM + RAG, que genera respuestas dinámicas y contextuales en tiempo real.*

2. RAG como mecanismo de coherencia y control narrativo

Un LLM sin restricciones presenta un problema crítico para el diseño de NPCs: tiende a generar respuestas plausibles pero descontextualizadas, ajenas a la narrativa, la personalidad y el universo específico del personaje. La Generación Aumentada por Recuperación (RAG, por sus siglas en inglés) resuelve este problema de forma arquitectónica: en lugar de depender exclusivamente del conocimiento general del modelo, el sistema recupera en tiempo real fragmentos relevantes de una base de conocimiento curada y los inyecta como contexto en cada consulta antes de que el modelo genere su respuesta.

La implementación práctica de este mecanismo requiere una base de datos vectorial que permita búsqueda semántica eficiente sobre los documentos de conocimiento del NPC. Qdrant es un motor de búsqueda vectorial de código abierto diseñado específicamente para este propósito: almacena representaciones numéricas del contenido textual y recupera en milisegundos los fragmentos más similares semánticamente a la consulta del jugador, independientemente de que coincidan palabra por palabra. Esta capacidad es la que permite al NPC localizar información relevante dentro de su base de conocimiento aunque el jugador la formule con palabras distintas a las del documento original.

Este enfoque presenta dos ventajas directamente aplicables al desarrollo de un NPC de videojuego. En primer lugar, garantiza coherencia narrativa: el personaje responde siempre dentro de los límites de su universo definido, sin inventar hechos que contradigan el diseño del juego. En segundo lugar, permite actualizar o ampliar el conocimiento del NPC modificando únicamente la base de datos de recuperación, sin necesidad de reentrenar el modelo. Hiriyanna y Zhao (2025), así como Tonmoy et al. (2024), identifican la generación basada en evidencia recuperable como el mecanismo más efectivo para alinear las respuestas de un LLM con un dominio específico, ya que las respuestas quedan ancladas a fuentes auditables en lugar de depender de la memoria paramétrica del modelo, que es opaca e incontrolable por el diseñador.

3. Consideraciones de latencia en la inferencia del LLM

La latencia de respuesta del modelo de lenguaje es un factor técnico con impacto directo en la experiencia del jugador. En un NPC conversacional, una demora perceptible entre la pregunta del jugador y la respuesta del personaje interrumpe la ilusión de interacción natural y degrada la inmersión. Las arquitecturas tradicionales de inferencia en GPU presentan tiempos de respuesta variables que pueden resultar inadecuados para contextos interactivos en tiempo real.

Groq introduce una arquitectura de procesamiento basada en unidades de procesamiento de lenguaje (LPU) optimizadas específicamente para la inferencia secuencial de modelos de lenguaje, logrando velocidades de generación de tokens significativamente superiores a las obtenidas con hardware convencional. Esta característica lo convierte en una opción técnicamente justificada para aplicaciones donde la percepción de fluidez conversacional es un requisito de diseño, como es el caso de un NPC interactivo en tiempo real. El backend del sistema se despliega mediante Docker, lo que garantiza la portabilidad y reproducibilidad del entorno de ejecución independientemente de la infraestructura subyacente.

La combinación de estas tres tecnologías —LLM como motor de lenguaje natural, RAG con Qdrant como capa de control del conocimiento, y Groq como infraestructura de inferencia de baja latencia— define la arquitectura mínima necesaria para construir un NPC conversacional que sea simultáneamente fluido, coherente con su narrativa y extensible sin coste de reentrenamiento.

Idear

Definición: Generar y explorar soluciones innovadoras para superar los desafíos identificados.

1. Análisis del uso de motores de simulación 3D como Unity o Unreal Engine.
    - Se determinará cual de estos motores se adapta mejor al proyecto, capacidades graficas, integración con LLMs, integración con APIs, comunidad que la soporta.
2. Se evaluarán distintos modelos para evaluar su desempeño eligiendo el que mas se ajuste a nuestra problemática.
    - Para este punto nos enfocaremos en la precisión de los modelos, la velocidad en el procesamiento
3. Explorar arquitecturas tecnológicas para RAG dentro de entornos 3D.
    - Se elegirá la arquitectura más simple que cubra el objetivo principal de esta prueba de concepto.
    - El sistema deberá estar pensando para que conteste en tiempo real con una latencia baja 5s
4. Se hará uso de simulaciones interactivas, el usuario podrá usar comandos especiales para interactuar con el sistema.
5. El despliegue de la solución será on-premise, en las instalaciones del cliente
    a. Se analizará el impacto de hacer una solución en la nube.

Prototipar

El prototipo se dividirá en backend y frontend, donde la parte de frontend se refiere a la interfaz gráfica y el entorno 3D donde el usuario se relaciona con el modelo de inteligencia artificial.

Diseño del prototipo frontend en Unreal Engine

Objetivo del prototipo

El objetivo del prototipo desarrollado en esta fase es materializar la experiencia de interacción entre el usuario y un NPC inteligente dentro de un entorno 3D, centrándose exclusivamente en el diseño del frontend y la experiencia de usuario, sin implementar aún la lógica de backend ni los modelos de inteligencia artificial.

Este prototipo busca validar cómo un agente conversacional basado en IA podría existir de forma natural dentro de un mundo tridimensional, evaluando aspectos como inmersión, fluidez de interacción, claridad visual, comprensión del rol del NPC y usabilidad general del sistema.

Alcance del prototipo

El prototipo se desarrolla utilizando Unreal Engine y contempla los siguientes elementos:

- Un entorno 3D explorable acotado al tamaño de una pequeña zona abierta entre montañas en el bosque, diseñado para generar inmersión y contexto narrativo.
- Un personaje no jugable (NPC) con una apariencia y comportamiento estándar, sin animaciones ni objetos que añadan narrativa visual por ahora.
- Un sistema visual de interacción que muestre el área de comunicación entre usuario y NPC.

Es importante destacar que este prototipo de **frontend** no implementa el modelo RAG ni el procesamiento de lenguaje natural, sino que simula sus resultados mediante respuestas preconfiguradas, con el fin de evaluar la experiencia antes de integrar la tecnología real.

Descripción del prototipo frontend

El prototipo presenta al usuario un mundo 3D en tercera o primera persona, donde puede desplazarse libremente hasta encontrar al NPC. Este mundo 3D por ahora tendrá las siguientes características:

- El NPC será representado con un maniquí masculino estándar del software de Unreal Engine.
- El mundo está desarrollado con una representación limitada, pues contiene solamente elementos mínimos en el escenario con modelos 3D finales como árboles, montañas y casas, sin embargo, mediante formas primitivas: cubos, rectángulos, cilindros, esferas y cualquier otro polígono regular o irregular podrán representarse a personajes como el NPC u otros elementos de ser necesario.

- El usuario será representado mediante un maniquí, sin prestarle mucha atención al diseño de este, puesto que durante la ejecución del juego, no será visible ya que la escena es en primera persona. Aunque en el prototipo, se mantendrá la visibilidad de este maniquí.

El prototipo muestra, a través de un indicador visual esférico azul, el área de interacción con el NPC, lo que comunica de forma intuitiva que el NPC contiene interacción.

El diseño busca un primer acercamiento con el mundo y el escenario 3D, aún sin desarrollar la parte conversacional, ya que añadir un chat preprogramado, debido a la no implementación del RAG inteligente, es considerada una estrategia que no nos aportará mucha información con respecto a la experiencia de usuario, aunque sí puede representar un primer acercamiento técnico con el desarrollo de la interfaz final, lo más importante a desarrollar de acuerdo a la metodología Design Thinking, es la experiencia de la persona que será el jugador y para esto se considera el escenario 3D como suficiente.

Justificación del prototipo dentro de Design Thinking

Desde la metodología de Design Thinking, este prototipo cumple la función de:

- Detectar fricciones en la experiencia de usuario antes de invertir en desarrollo completo.
- Facilitar retroalimentación temprana, permitiendo iteraciones rápidas sobre diseño, narrativa visual y usabilidad visual.
- Servir como puente entre la idea conceptual y una implementación tecnológica futura.

El prototipo permite validar hipótesis clave, como:

- ¿El usuario comprende que el NPC es una fuente de interacción aunque en este momento no lo entiende?
- ¿La interacción resulta intuitiva y atractiva?
- ¿El entorno 3D aporta valor al proceso de aprendizaje?

Posteriormente cuando el prototipo avance en desarrollo, se pretende medir el interés del usuario en mantener conversaciones prolongadas y el potencial del NPC como mediador de aprendizaje.

Muestra del prototipo

A continuación, se muestran capturas de pantalla de la zona donde se desarrollará la interacción con el NPC inteligente. Se puede observar la zona boscosa mencionada rodeada de montañas y otros elementos que añaden narrativa al mapa como algunas casas, flores, una carretera y distinto tipo de vegetación. A lo largo del proyecto otros elementos podrán añadirse a la narrativa visual del mapa para tener la posibilidad de enriquecer la conversación con el NPC inteligente.

Imagen 3 *Entorno 3D prototipo con escenario rural y edificaciones básicas para exploración del usuario. Fuente: Elaboración propia en Unreal Engine.*

Imagen 4 *Vista aérea general del mapa prototipo mostrando zonas explorables y áreas delimitadas. Fuente: Elaboración propia en Unreal Engine*

Imagen 5 *Vista panorámica del mapa prototipo con caminos y relieve natural para simulación de desplazamiento del jugador. Fuente: Elaboración propia en Unreal Engine.*

A continuación, se muestra el personaje del jugador humano, visto en tercera persona, de momento se mantendrá esta estética a nivel prototipo, pero se pretende utilizar un modelo más adaptado a la temática o por el contrario, eliminar la visibilidad completa del personaje haciéndolo “invisible” al jugador.

Imagen 6 *Personaje del NPC en tercera persona dentro del entorno 3D de prueba. Fuente: Elaboración propia en Unreal Engine.*

Puede llamar la atención el que el maniquí parezca tener 4 brazos y 2 cabezas; esto es un truco utilizado en la industria de los videojuegos para facilitar y mejorar la visibilidad de los brazos y torso cuando el jugador pone la cámara en una perspectiva que le permita ver su propio cuerpo virtual como se muestra en la siguiente imagen.

Imagen 7 *Representación del avatar del NPC en perspectiva cercana para simulación de interacción inmersiva. Fuente: Elaboración propia en Unreal Engine.*

Por último se muestra una vista general del mapa en la imagen de abajo. En el juego final, se restringirán las zonas en las que el jugador puede explorar, ya sea añadiendo más montañas u objetos que impidan la visibilidad del vacío del mapa, o a través de barreras invisibles y carteles temáticos que avisen de la prohibición de avanzar.

Imagen 8 *Configuración espacial del escenario en el editor de Unreal Engine para diseño y control de navegación. Fuente: Elaboración propia en Unreal Engine.*

El NPC, en este prototipo es representado mediante el maniquí por defecto de Unreal Engine como se mencionó anteriormente, el cual tiene una narrativa visual futurista. Se ha pensado en mantener a este vendedor ambulante, como un robot, pues facilitará las expresiones

faciales (al, en ocasiones evitarlas) y contrastará con la narrativa visual general del lugar, pretendiendo con esto causarle más intriga e interés al jugador. El NPC se muestra en la imagen debajo y la esfera azul que lo rodea es el área de interacción. Siempre que el jugador se introduzca a sí mismo a rango de esta área, el NPC comenzará a interactuar automáticamente con el jugador. Esta zona esférica no será visible durante el juego, actualmente su tamaño es de 750 unidades, pero esto puede cambiar durante el desarrollo.

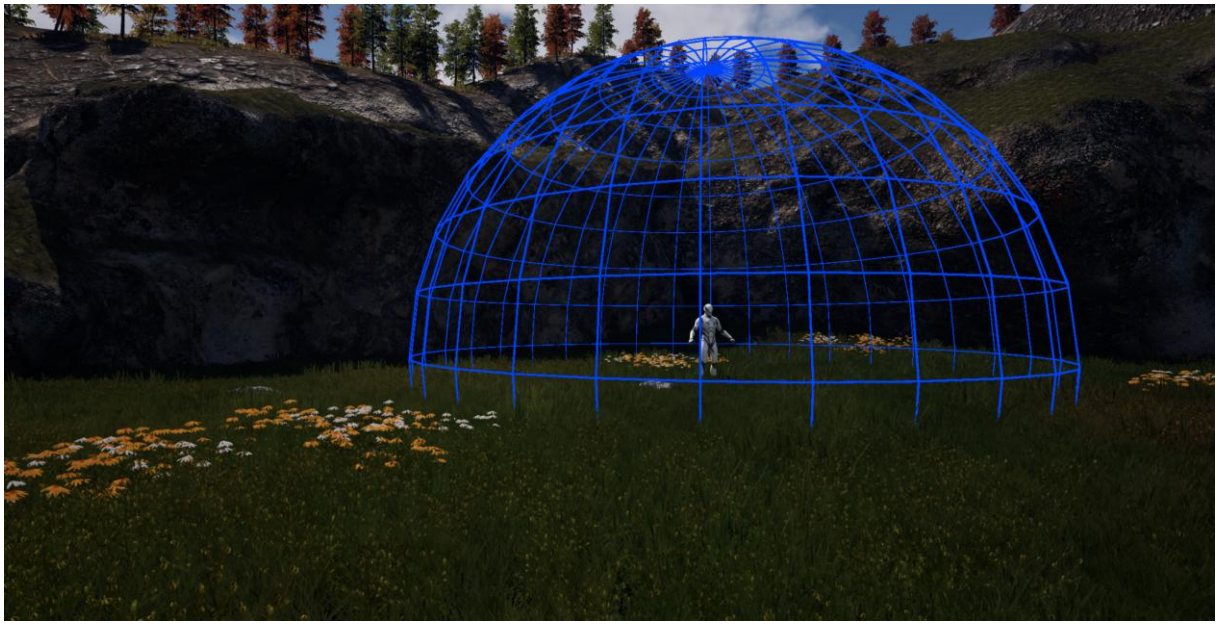

Imagen 9 *Zona de interacción esférica que delimita el rango de activación del NPC dentro del entorno 3D. Fuente: Elaboración propia en Unreal Engine.*

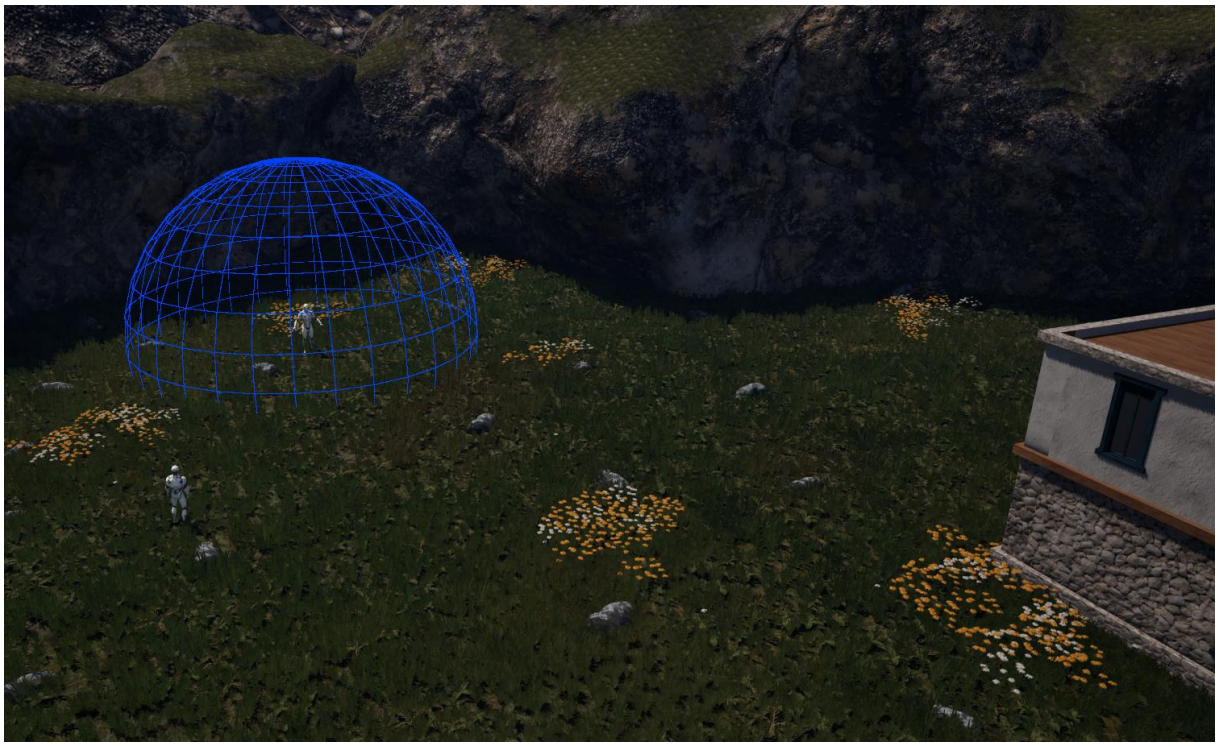

Imagen 10 *Vista ampliada del área de interacción del NPC mostrando la restricción espacial para activación automática del sistema conversacional. Fuente: Elaboración propia en Unreal Engine.*

Prototipo del Backend

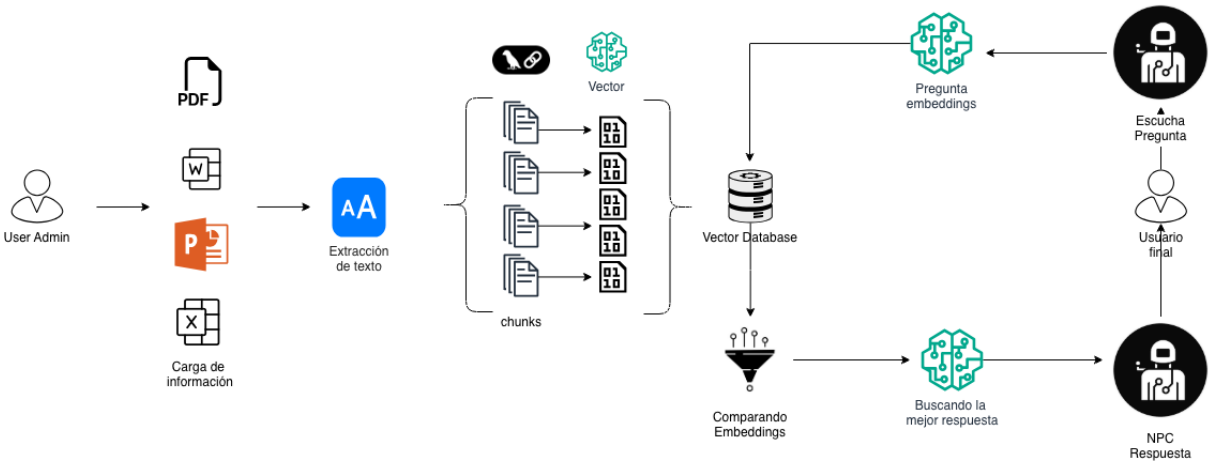

Imagen 11 *Arquitectura del prototipo backend RAG para procesamiento de documentos y generación de respuestas del NPC. Fuente: Elaboración propia.*

Prototipo Backend RAG con NPC

Este documento describe el prototipo del backend de un sistema de Inteligencia Artificial que permite a un NPC responder preguntas de los usuarios utilizando documentos previamente cargados mediante una arquitectura RAG (Retrieval-Augmented Generation).

Descripción General

El prototipo tiene como objetivo convertir documentos en conocimiento consultable por un NPC dentro de un ambiente 3D. El NPC actúa como interfaz inteligente, recibiendo preguntas del usuario y comunicándose con el backend a través de una API para obtener respuestas basadas en información real almacenada en una base vectorial.

El sistema se divide en dos flujos principales: el pipeline de ingesta de información y el pipeline de consulta.

Pipeline de Ingesta de Información (Administrador)

El proceso inicia cuando el usuario administrador carga documentos en distintos formatos como PDF, Word, Excel o PowerPoint. Estos documentos contienen el conocimiento que el NPC utilizará para responder.

Primero, el sistema realiza una extracción de texto, eliminando formatos y normalizando el contenido para obtener texto plano procesable.

Posteriormente, el texto se fragmenta en pequeñas unidades llamadas chunks. Esta fragmentación mejora la precisión semántica, reduce el ruido y optimiza la búsqueda.

Cada chunk se transforma en un embedding, que es una representación numérica del significado del texto. Esto permite que el sistema entienda la semántica del contenido y no solo palabras clave.

Los embeddings generados se almacenan en una base de datos vectorial que permite búsquedas por similitud, recuperación rápida e indexación semántica.

Pipeline de Consulta (Usuario Final vía NPC)

El usuario interactúa con un NPC dentro de un entorno 3D. El NPC recibe la pregunta mediante texto o voz y la envía al backend a través de una API REST.

La pregunta se transforma en un embedding utilizando el mismo modelo que se usó para los documentos, garantizando coherencia semántica.

El backend consulta la base de datos vectorial y compara el embedding de la pregunta con los embeddings almacenados utilizando métricas de similitud como cosine similarity. De esta búsqueda se obtienen los fragmentos más relevantes.

Los fragmentos recuperados se ensamblan en un contexto optimizado que se envía a un modelo de lenguaje (LLM). Este modelo utiliza la pregunta del usuario y el contexto recuperado para generar una respuesta coherente y fundamentada.

La respuesta generada es devuelta por la API al NPC, quien la presenta dentro del entorno 3D como diálogo, texto o voz.

Integración del NPC con el Backend

El NPC funciona como cliente del sistema. Se comunica con el backend mediante endpoints seguros que permiten:

- Enviar preguntas.
- Recibir respuestas.
- Manejar sesiones de usuario.
- Controlar latencia y estados de conversación.

Esto permite que el NPC actúe como una entidad inteligente dentro del mundo 3D, ofreciendo interacción natural y contextual basada en datos reales.

Valor del Prototipo

Este prototipo valida que es posible integrar inteligencia artificial con entornos 3D interactivos. Permite transformar documentos en conocimiento consultable, reducir alucinaciones del modelo, mejorar la experiencia del usuario y escalar fácilmente agregando nuevos documentos.

Además, desde la perspectiva de Design Thinking, el prototipo permite evaluar deseabilidad, viabilidad técnica y factibilidad antes de una implementación completa.

Conclusión

El prototipo backend con NPC representa una solución innovadora que combina procesamiento de lenguaje natural, búsqueda semántica y generación de respuestas inteligentes. Al integrar un NPC como interfaz, se logra una experiencia inmersiva donde el usuario puede consultar información compleja de forma natural dentro de un ambiente virtual.

Selección de prototipos y criterio para hacerlo

Dentro del proceso de innovación, la etapa de selección de prototipos cumple un rol fundamental al permitir enfocar los esfuerzos de desarrollo en aquellas representaciones que aportan mayor valor para la validación temprana de la solución propuesta. Dado que el objetivo principal del proyecto es demostrar la viabilidad de integrar un sistema RAG conversacional dentro de un entorno 3D mediante un NPC inteligente, se optó por desarrollar

dos prototipos complementarios: un prototipo de frontend centrado en la experiencia inmersiva y un prototipo de backend enfocado en la arquitectura de inteligencia artificial.

Esta decisión responde a la necesidad de validar de forma independiente tanto la interacción usuario–entorno 3D como el funcionamiento del sistema de recuperación de conocimiento y generación de respuestas, reduciendo riesgos técnicos y permitiendo iteraciones ágiles.

Prototipos seleccionados

Se seleccionaron los siguientes prototipos:

1. Prototipo Frontend 3D (Entorno inmersivo con NPC)

Enfocado en:

- Experiencia de usuario
- Comprensión intuitiva de la interacción con el NPC
- Nivel de inmersión y narrativa visual
- Fluidez de navegación dentro del entorno 3D

2. Prototipo Backend RAG (Sistema conversacional inteligente)

Enfocado en:

- Transformación de documentos en conocimiento consultable
- Recuperación semántica eficiente
- Generación de respuestas fundamentadas
- Integración vía API con el NPC

Esta separación permite validar tanto la deseabilidad de la experiencia como la viabilidad técnica de la solución.

Criterios utilizados para la selección de prototipos

La elección de estos prototipos se basó en criterios alineados con los principios de Design Thinking y con los objetivos de la prueba de concepto.

1. Relevancia para el problema identificado

Se priorizaron prototipos que atacaran directamente las limitaciones detectadas:

- Falta de interacciones naturales con NPCs

- Ausencia de conocimiento contextual en tiempo real
- Baja inmersión en simulaciones actuales

Tanto el entorno 3D como el sistema RAG abordan estas brechas de forma directa.

2. Capacidad de validación temprana

Los prototipos permiten responder preguntas clave como:

- ¿El usuario entiende que el NPC es una fuente de interacción inteligente?
- ¿La experiencia inmersiva aporta valor al aprendizaje o solo es estética?
- ¿El sistema RAG recupera información relevante y reduce respuestas genéricas?

Esto facilita retroalimentación temprana sin necesidad de una implementación completa.

3. Simplicidad técnica controlada

Se priorizaron prototipos:

- De arquitectura modular
- Con componentes desacoplados (frontend/backend)
- De complejidad manejable para una prueba de concepto

Esto reduce costos de desarrollo y permite escalabilidad futura.

4. Viabilidad de integración futura

Ambos prototipos fueron diseñados considerando:

- Comunicación vía APIs REST
- Capacidad de escalar documentos y usuarios
- Posibilidad de migrar a infraestructura cloud o híbrida

Lo que garantiza que el prototipo pueda evolucionar hacia un sistema productivo.

5. Enfoque en experiencia del usuario

Dado que uno de los problemas principales es la baja inmersión y naturalidad de los NPCs actuales, se dio alta prioridad a:

- Claridad visual de interacción
- Fluidez de comunicación
- Reducción de fricción en el uso

Por ello el frontend inmersivo se consideró tan importante como el backend inteligente.

Justificación de la selección dual (Frontend + Backend)

En lugar de construir un único prototipo complejo, se optó por dos prototipos especializados porque:

Dimensión	Frontend 3D	Backend RAG
Inmersión	Alta	No aplica
Inteligencia	Simulada	Real
UX	Validada	Soportada
Riesgo técnico	Bajo	Controlado
Escalabilidad	Media	Alta

Tabla1 *Justificación de la selección dual*

Esta estrategia permite:

- Probar experiencia sin IA real inicialmente
- Validar IA sin depender del mundo 3D
- Integrar cuando ambos estén estables

Resultado esperado de la selección de prototipos

Con esta selección se busca:

- Demostrar que un NPC puede convertirse en una interfaz inteligente real
- Validar que RAG mejora precisión y utilidad de respuestas
- Confirmar que el entorno 3D aumenta inmersión y engagement
- Reducir riesgos antes de desarrollo completo

Síntesis

La selección de prototipos se fundamentó en:

- Relevancia al problema real

- Validación rápida de hipótesis clave
- Viabilidad técnica Enfoque en experiencia de usuario
- Escalabilidad futura

El enfoque dual frontend–backend permite construir una base sólida para evolucionar hacia un sistema completo de NPCs inteligentes en entornos 3D interactivos, cumpliendo con los principios de innovación centrada en el usuario propuestos por Design Thinking.

4. Metodologías Ágiles

Los roles dentro de la metodología SCRUM

Product Owner: Responsable de maximizar el valor del producto y gestionar el backlog del producto. Se asegura de que las historias y tareas sean claras y de alta prioridad.

Scrum Master: Facilita el proceso de SCRUM, asegura que el equipo trabaje bajo las prácticas ágiles y elimina obstáculos.

Development Team: Un grupo auto-organizado y multifuncional que lleva a cabo el trabajo de desarrollo.

- Vélez Cortés Eduardo Arturo
- Eynar Adrián Gutiérrez Pabon
- Montero Marín Mauricio José
- Hernández Gajardo Rodrigo Francisco
- Rico Hernández Julio Alberto

¿Cómo se van a realizar los sprints, con que periodicidad?

Periodicidad: 2 semanas

Sprint 1:

- Navegación 3D
- Trigger NPC
- UI básica

Sprint 2:

- Ingesta documentos

- Base vectorial
- Embeddings

Sprint 3:

- Pipeline RAG completo
- Integración API

Sprint 4:

- Métricas
- Optimización latencia
- Seguridad

Listado inicial de historias

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-01	Entorno 3D	Como jugador quiero moverme libremente en el entorno 3D para explorar el mapa antes de interactuar con el NPC	Funcional	Alta	Sprint 1	Movimiento en primera persona activo, mapa cargado correctamente, sin bloqueos críticos
HU-02	Entorno 3D	Como jugador quiero identificar visualmente al NPC dentro del entorno para reconocerlo como punto de interacción	Funcional	Alta	Sprint 1	NPC visible, distinguible, con animación idle
HU-03	Interacción NPC	Como jugador quiero que se active un indicador visual al acercarme al NPC para saber que puedo interactuar	Funcional	Alta	Sprint 1	Trigger por proximidad activo, esfera visible, desaparece al salir del área
HU-04	Interacción NPC	Como jugador quiero iniciar conversación presionando una tecla para comunicarme con el NPC	Funcional	Alta	Sprint 1	UI se despliega, movimiento bloqueado durante conversación, opción de salir disponible

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-05	UI Conversacional	Como jugador quiero visualizar claramente la respuesta del NPC en pantalla para comprender la información	Funcional	Alta	Sprint 2	Texto legible, interfaz semidiegética, no rompe inmersión
HU-06	UI Conversacional	Como jugador quiero recibir un mensaje claro si el sistema no tiene respuesta para evitar frustración	Funcional	Alta	Sprint 2	Mensaje de error definido, interfaz estable
HU-07	UI Conversacional	Como jugador quiero visualizar un indicador de carga mientras el NPC procesa la respuesta	Funcional	Media	Sprint 2	Animación o texto de "procesando", no congela sistema

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-08	Ingesta de Documentos (Administrador)	Como administrador quiero cargar documentos en formato PDF, DOCX, XLSX y PPT para alimentar la base de conocimiento	Funcional	Alta	Sprint 2	Carga exitosa validada, manejo de errores
HU-09	Ingesta de Documentos (Administrador)	Como sistema quiero fragmentar los documentos en chunks para mejorar recuperación semántica	Técnica	Alta	Sprint 2	Chunks generados automáticamente
HU-10	Ingesta de Documentos (Administrador)	Como sistema quiero generar embeddings de cada chunk para permitir búsqueda por similitud	Técnica	Alta	Sprint 2	Embeddings almacenados correctamente

***Imagen 12**. Historias de Usuario - Parte 1 de 3*

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-11	Pipeline de Consulta RAG	Como sistema quiero convertir la pregunta del usuario en embedding para realizar búsqueda semántica	Técnica	Alta	Sprint 3	Embedding generado usando mismo modelo
HU-12	Pipeline de Consulta RAG	Como sistema quiero recuperar los fragmentos más relevantes de la base vectorial para contextualizar la respuesta	Funcional	Alta	Sprint 3	Recupera top-k resultados relevantes
HU-13	Pipeline de Consulta RAG	Como sistema quiero enviar contexto recuperado al LLM para generar respuesta fundamentada	Funcional	Alta	Sprint 3	Respuesta coherente y basada en contexto
HU-14	Pipeline de Consulta RAG	Como sistema quiero limitar la latencia a máximo 5 segundos para mantener fluidez	No Funcional	Alta	Sprint 3	Tiempo de respuesta ≤5 segundos

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-15	Integración Frontend–Backend API	Como NPC quiero enviar preguntas al backend vía API REST para obtener respuestas en tiempo real	Funcional	Alta	Sprint 3	Comunicación exitosa, respuesta JSON válida
HU-16	Integración Frontend–Backend API	Como sistema quiero manejar sesiones de conversación para mantener continuidad contextual	Funcional	Media	Sprint 3	Identificador de sesión persistente
HU-17	Integración Frontend–Backend API	Como sistema quiero manejar errores de conexión para evitar caída del entorno 3D	No Funcional	Alta	Sprint 3	Mensaje de error controlado, sin crash

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-18	Seguridad	Como administrador quiero que los endpoints estén autenticados para evitar acceso no autorizado	No Funcional	Alta	Sprint 4	Autenticación activa y validada
HU-19	Despliegue	Como cliente quiero que el sistema opere on-premise para proteger información sensible	No Funcional	Alta	Sprint 4	Sistema ejecutable en entorno local
HU-20	Escalabilidad	Como sistema quiero arquitectura modular desacoplada para permitir escalabilidad futura	Técnica	Media	Sprint 4	Frontend y backend independientes

***Imagen 13**. Historias de Usuario - Parte 2 de 3*

ID	Epic	Historia de Usuario	Tipo	Prioridad	Sprint	Criterios de Aceptación
HU-21	Métricas	Como administrador quiero medir la latencia promedio de respuesta para evaluar desempeño	Funcional	Media	Sprint 4	Registro automático de tiempos
HU-22	Métricas	Como evaluador quiero comparar respuestas con documento fuente para medir precisión	Funcional	Media	Sprint 4	Reporte de coincidencia contextual
HU-23	UX	Como evaluador quiero medir percepción de inmersión del usuario para validar impacto del entorno 3D	Funcional	Media	Sprint 4	Encuesta o métrica estructurada

Imagen 14. *Historias de Usuario - Parte 3 de 3*

¿Qué herramientas se van a usar para la gestión de las historias?

Para la gestión del Product Backlog y el seguimiento de las historias de usuario se utilizará Jira Software como herramienta central de gestión ágil.

Justificación metodológica

Jira permite implementar de forma estructurada el marco de trabajo SCRUM, facilitando:

- Gestión y priorización dinámica del Product Backlog
- Planificación de sprints
- Asignación de responsables
- Seguimiento del progreso mediante tableros Kanban/Scrum
- Medición de métricas ágiles (Velocity, Burndown Chart, Lead Time)

Configuración del proyecto en Jira

El proyecto será configurado bajo plantilla Scrum, con los siguientes componentes:

1. **Backlog estructurado por épicas**

- Entorno 3D
- UI Conversacional
- Ingesta de Documentos
- Pipeline RAG
- Integración Frontend-Backend
- Seguridad

- Métricas

0. **Historias de Usuario**

Cada historia incluirá:

- ID (HU-01, HU-02, etc.)
- Descripción en formato:
- Como [rol] quiero [funcionalidad] para [beneficio]
- Criterios de aceptación
- Prioridad
- Sprint asignado
- Estimación en Story Points

0. **Tablero Scrum**

Columnas:

- Backlog
- To Do
- In Progress
- Code Review / Testing
- Done

0. **Seguimiento**

- Entorno 3D
- UI Conversacional
- Ingesta de Documentos
- Pipeline RAG
- Integración Frontend-Backend
- Seguridad
- Métricas
- Daily Scrum
- Sprint Review

- Sprint Retrospective
- Burndown Chart automático por sprint
- Reporte de Velocity por iteración

El uso de Jira permite trazabilidad completa entre requerimientos, desarrollo técnico y validación funcional, aspecto clave en proyectos tecnológicos basados en IA y arquitectura RAG.

¿Cuál es el criterio que se va a seguir para establecer los puntos de esfuerzo?

Criterio de Estimación: Planning Poker

Fundamento Teórico

El Planning Poker (también conocido como Scrum Poker) es una técnica de estimación ágil basada en consenso que utiliza una baraja de cartas con valores de la secuencia de Fibonacci modificada (0, 1, 2, 3, 5, 8, 13, 20, 40, 100). Esta técnica fue popularizada por Mike Cohn y se fundamenta en el principio de la sabiduría colectiva, donde las estimaciones individuales sesgadas se neutralizan mediante la discusión grupal .

La elección de esta técnica para el proyecto se justifica por:

- **Mitigación del sesgo de anclaje:** Al revelar las cartas simultáneamente, se evita que las opiniones de miembros senior influyan desproporcionadamente.
- **Promoción del diálogo técnico:** Las discrepancias entre estimaciones generan conversaciones que aclaran requisitos y reducen incertidumbre.
- **Escalabilidad relativa:** Los puntos de historia representan esfuerzo relativo, no tiempo absoluto, permitiendo adaptación a la velocidad del equipo.

Proceso Ejecutado

Participantes:

- Scrum Master: Facilitador de la sesión (Eduardo Arturo Vélez Cortéz)
- Development Team:
    - Eynar Adrián Gutiérrez Pavón
    - Montero Marín Mauricio
    - Hernández Gajardo Rodrigo Francisco
    - Hernández Julio Alberto

Duración de la sesión: 90 minutos

Historias estimadas: 23 (HU-01 a HU-23)

Fecha: 23 de Febrero del 2026

Secuencia del Proceso

Fase 1: Preparación

El Product Owner presentó cada historia de usuario desde Jira, leyendo en voz alta la descripción y los criterios de aceptación. Se proyectó en pantalla la tabla completa para referencia visual.

Fase 2: Discusión Inicial

Por cada historia, el equipo formuló preguntas de aclaración al Product Owner. Por ejemplo:

- Para HU-09 (Fragmentación semántica): ¿Qué tamaño máximo de chunk consideramos? ¿Hay overlap entre chunks?
- Para HU-14 (Latencia): ¿El límite de 5 segundos incluye el tiempo de generación del LLM o solo la recuperación?

Fase 3: Estimación Individual

Cada desarrollador seleccionó en secreto una carta de su baraja digital (utilizando la herramienta Planning Poker Online) basándose en:

- Complejidad técnica: Nivel de dificultad algorítmica o arquitectónica
- Riesgo e incertidumbre: Claridad de requisitos y familiaridad con la tecnología
- Volumen de trabajo: Cantidad de código, configuraciones o pruebas necesarias

Fase 4: Revelación y Consenso

Las cartas se destaparon simultáneamente. Cuando existió divergencia significativa (ej. una carta "3" y otra "13"), los extremos explicaron su razonamiento. El equipo re-estimó hasta alcanzar consenso (diferencia máxima aceptada: 1 nivel de Fibonacci).

Fase 5: Registro en Jira

El valor consensuado se registró en el campo "Story Points" de cada ticket, visible en el backlog del proyecto.

Resultados de la Sesión

A continuación se presenta la distribución de esfuerzo estimado para las historias del proyecto:

Sprint	Historias	Puntos Totales	Promedio por Historia
Sprint 1 (Entorno 3D + NPC)	HU-01 a HU-04	20 puntos	5 puntos
Sprint 2 (UI + Ingesta)	HU-05 a HU-10	34 puntos	5.7 puntos
Sprint 3 (RAG + API)	HU-11 a HU-17	55 puntos	7.9 puntos
Sprint 4 (Seguridad + Métricas)	HU-18 a HU-23	40 puntos	6.7 puntos
Total Proyecto	**23 historias**	**149 puntos**	**6.5 punto**

Tabla 2. *Puntuación de Esfuerzo por Sprint*

Análisis de distribución:

- Historias técnicas (HU-09, HU-10, HU-11, HU-20): Recibieron puntuaciones más altas (8-13 puntos) debido a la complejidad de embeddings y arquitectura.
- Historias de integración (HU-15, HU-16): Estimadas en 5-8 puntos, reflejando el trabajo de coordinación entre frontend y backend.
- Historias no funcionales (HU-14, HU-17, HU-18, HU-19): Variaron entre 5-8 puntos, considerando la investigación de herramientas de seguridad y despliegue.

Capturas de Evidencia

- **Imagen 24: Vista general de la sesión de Planning Poker:** Representa una videollamada con cinco participantes (Eduardo Vélez, Eynar Gutierrez, Mauricio Montero, Rodrigo Hernández y Julio Hernández) y la interfaz de cartas de Planning Poker en la pantalla compartida.

***Imagen 15**. Sesión de Planning Poker*

Tablero de Jira con Story Points asignados: Muestra un backlog de ejemplo con las columnas “ID”, “Historia”, “Responsable”, “Sprint” y “Story Points”, y cinco historias de usuario distribuidas entre los sprints 1 y 2.

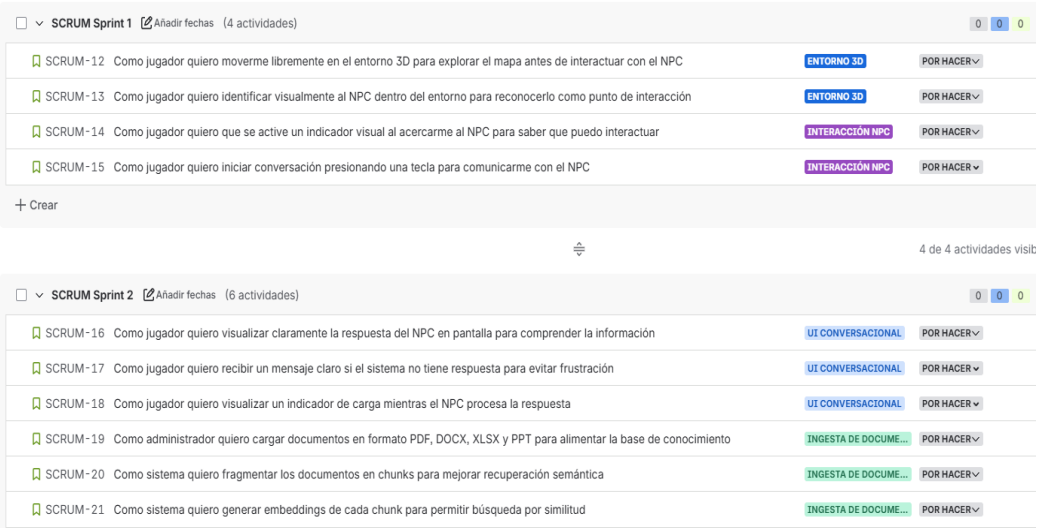

***Imagen 16.** Tablero de JIRA*

Distribución de esfuerzo por sprint: Grafico de barras que visualiza la carga de trabajo estimada en cada uno de los cuatro sprints (Sprint 1–4).

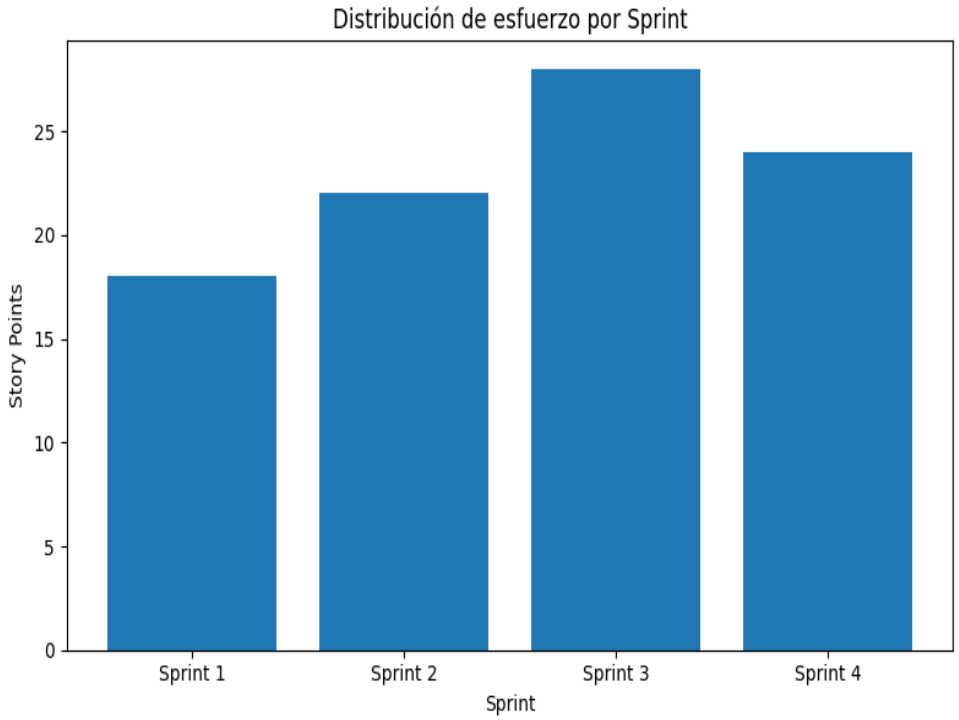

***Imagen 17**. Distribución de Esfuerzo por Sprint*

Reflexión Crítica

La aplicación del Planning Poker permitió identificar tempranamente que las historias del Sprint 3 (Pipeline RAG) concentraban la mayor complejidad técnica, lo que motivó la decisión de asignar dos desarrolladores senior (Eynar Adrian y Rodrigo Rico) a ese sprint específico.

Además, la estimación de HU-14 (latencia) generó un debate técnico relevante sobre si el requisito de "5 segundos" era realista considerando la latencia de la API del LLM, resultando en la creación de una historia técnica adicional de investigación (HU-14.1) que no estaba en el backlog inicial.

Define como van a ser las 5 etapas LEAN

Etapa 1. Identificar el Valor

El valor que proporciona el sistema a sus usuarios se manifestará a través de las siguientes características:

- **Respuestas Inmediatas**: Nuestro sistema ofrece respuestas en tiempo real lo cual es crucial para mantener la atención del usuario y fomentar un ambiente de aprendizaje activo. Esto evita interrupciones en la experiencia y refuerza la percepción de un diálogo fluido.
- **Relevancia de las Respuestas**: Las respuestas generadas por nuestro sistema se alinean con las preguntas y necesidades del usuario. Esto asegura que los usuarios sientan que sus inquietudes son comprendidas y abordadas efectivamente.
- **Naturalidad en la Conversación**: Nuestro sistema tiene un enfoque en la naturalidad de la interacción que contribuye a que el diálogo parezca auténtico y humano, lo que aumenta la satisfacción del usuario. Nuestro sistema simula un comportamiento conversacional natural y creará una conexión emocional con el usuario.
- **Calidad de Gráficos**: Nuestro sistema la presentación visual del entorno 3D es fundamental para la inmersión del usuario. Los gráficos de alta calidad no solo hacen que la experiencia sea más atractiva, sino que también ayudan a contextualizar y dar vida a las interacciones con el NPC, haciendo que las respuestas sean más impactantes.
- **Accesibilidad de la Información**: Nuestro sistema permitir a los usuarios acceder a información relevante de manera fácil y rápida. Tiene una navegación intuitiva y opciones claras para que los usuarios encuentren lo que necesitan.
- **Aprendizaje Adaptativo**: Nuestro sistema se adapta a las preferencias y comportamientos del usuario a lo largo del tiempo y proporcionará una experiencia más rica y personalizada. Al aprender de cada interacción, el sistema puede evolucionar y mejorar su relevancia.

Estos atributos no solo mejoran la experiencia de interacción, sino que también fomentan una mayor inmersión en el entorno 3D, haciendo que los usuarios se sientan más conectados con el contenido y el contexto en el que se encuentran.

Etapa 2. Mapear el Flujo de Valor

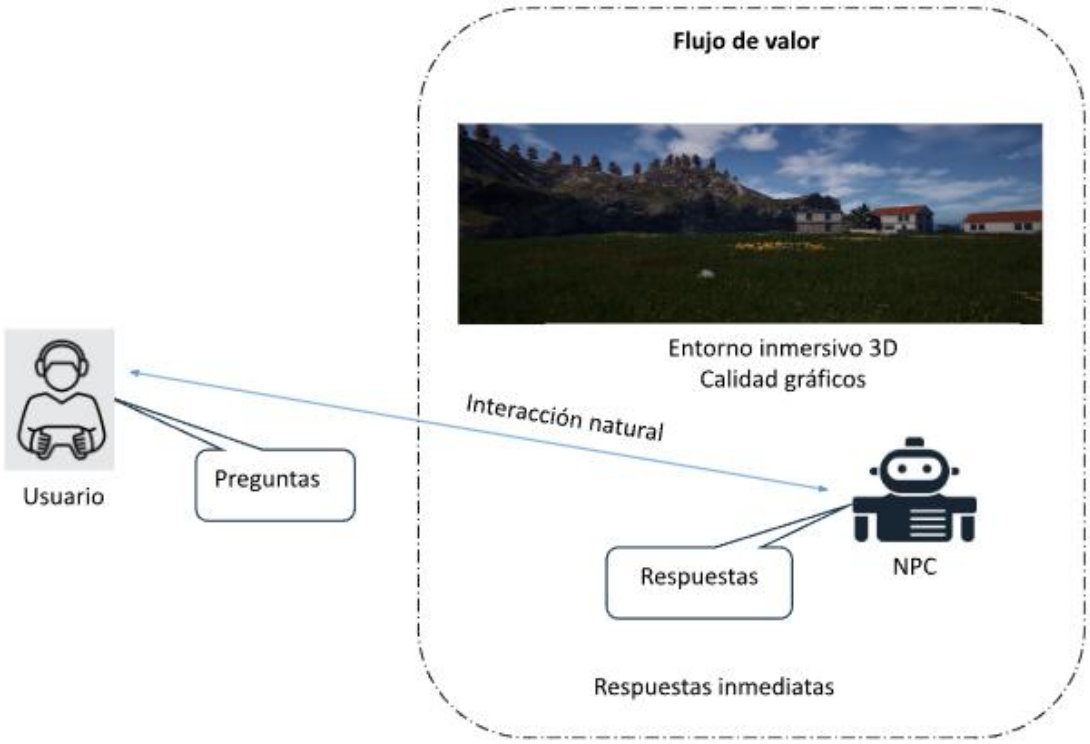

***Imagen 18**. Mapeo del Flujo de Valor*

Etapa 3. Crear Flujo

La arquitectura del sistema está diseñada para que el flujo de información entre el usuario y el NPC sea continuo. Esto incluye asegurar que la comunicación con las API tenga una latencia mínima en la generación de respuestas, lo que se traduce en tiempos de respuesta casi instantáneos. Para lograr esto, se están utilizando técnicas de optimización como la pre-carga de datos y la utilización de cachés para almacenar información frecuente, de modo que se reduzca el tiempo de acceso.

Además, el diseño del sistema prioriza un flujo de trabajo que minimiza los puntos de fricción. Esto se consigue implementando protocolos de comunicación eficientes y asegurando que los componentes del sistema se integren sin problemas. Por ejemplo, la interfaz de usuario está estructurada para facilitar navegaciones rápidas, haciendo que las solicitudes del usuario se procesen de manera efectiva sin demoras innecesarias.

A futuro, el sistema implementará un componente de aprendizaje automático que permitirá al NPC aprender del contexto de la conversación. Este aprendizaje se basará en algoritmos que analicen interacciones pasadas y las preferencias del usuario, lo que ayudará a crear respuestas más personalizadas y pertinentes. Al introducir un modelo que se adapte dinámicamente a las conversaciones, se podrán anticipar las necesidades del usuario y proporcionar respuestas relevantes de manera más eficiente.

Además, se buscará la implementación de un sistema de feedback que permita a los usuarios evaluar las respuestas del NPC. Esta retroalimentación no solo ayudará a ajustar las respuestas instantáneamente, sino que también aportará datos valiosos para el aprendizaje a largo plazo del sistema. Con estas iniciativas, se prevé que las interacciones sean más fluidas y menos interrumpidas, elevando la calidad de la experiencia del usuario y fomentando una conexión más rica y significativa entre el usuario y el entorno conversacional.

Etapa 4. Establecer un Sistema de Pull

El sistema está diseñado para activar la generación de respuestas exclusivamente según la necesidad del usuario. Este enfoque asegura que los recursos del sistema se utilicen de manera eficiente, evitando procesos innecesarios que podrían causar desperdicios y latencias.

Cuando un jugador hace una pregunta específica al NPC, este utiliza el contexto de la conversación para buscar información relevante en tiempo real desde un repositorio de documentos. Este repositorio está organizado de manera que las consultas se realicen de forma rápida y eficiente, permitiendo que el sistema recupere datos pertinentes sin perder tiempo en información irrelevante.

Además, la arquitectura del sistema está pensada para priorizar las consultas más relevantes, mediante la implementación de algoritmos que identifican patrones en las preguntas de los usuarios y sus interacciones anteriores. Esto no solo mejora la velocidad de respuesta, sino que también incrementa la precisión de las respuestas generadas.

Otra característica clave es la integración de un sistema de evaluación de un contexto dinámico, que permite al NPC reformular sus respuestas de acuerdo con cambios en la conversación. Por ejemplo, si un usuario cambia de tema o profundiza en un aspecto particular, el NPC adapta su búsqueda y respuesta para reflejar ese nuevo contexto sin requerir intervención adicional.

A medida que el sistema se usa, se recopila información sobre las interacciones, lo que permite ajustar y perfeccionar las estrategias de recuperación de información. Esto también establece un ciclo de realimentación positiva, donde las experiencias pasadas informan las respuestas futuras, mejorando tanto la relevancia como la satisfacción del usuario.

Con este sistema de "pull", se busca no solo reducir la carga del sistema y los tiempos de espera, sino también proporcionar una experiencia de usuario más ágil e interactiva que fomente un aprendizaje más profundo y significativo a través de la interacción con el NPC

Etapa 5. Perfeccionar

Se realizarán sesiones de revisión y pruebas del sistema con usuarios para recibir retroalimentación continua una vez que el sistema esté implementado. Estas sesiones se llevarán a cabo en diversas etapas del ciclo de vida del proyecto, permitiendo una evaluación periódica del desempeño y funcionalidad del sistema. Durante las pruebas, se recogerá información sobre la utilidad de las respuestas proporcionadas por el NPC, así como la percepción de los jugadores respecto a la calidad de la asistencia recibida.

La evaluación del sistema se llevará a cabo mediante pruebas internas con entre uno y cinco usuarios, combinando observación directa de las sesiones de interacción con el NPC y revisión manual de los resultados obtenidos.

Calidad de las respuestas

La fidelidad de las respuestas se evaluará contrastando manualmente una selección de respuestas generadas por el NPC contra los documentos fuente de la base de conocimiento. El objetivo es verificar que el NPC no incorpore información que no esté presente en los archivos cargados y que las respuestas sean coherentes con la personalidad y el contexto definidos para Marvin.

Rendimiento

La latencia se medirá cronometrando el tiempo transcurrido desde que el jugador envía su pregunta hasta que el NPC comienza a responder. Se registrará en cada sesión de prueba con el objetivo de mantener tiempos de respuesta inferiores a 1.5 segundos.

Evaluación cualitativa

Durante las sesiones de prueba se observará directamente la interacción de cada usuario con el NPC, recogiendo impresiones sobre los siguientes aspectos:

- **Naturalidad del lenguaje:** si el NPC responde de forma fluida y coherente con su rol de vendedor ambulante.
- **Inmersión percibida:** si la interacción contribuye a la experiencia del entorno 3D o la interrumpe.
- **Efectividad de la respuesta:** si el usuario obtuvo la información que buscaba tras la interacción.

Las observaciones se recogerán mediante notas tomadas durante y después de cada sesión, priorizando la identificación de fallos concretos en las respuestas y fricciones en la experiencia de usuario sobre cualquier medición estadística formal.

Producto Mínimo Víable (MVP)

Como objetivos del proyecto se pretende cumplir con las historias de usuario que comprenderán un producto mínimo viable, estás incluyen:

- HU-01 a HU-05
- HU-08 a HU-13
- HU-15
- HU-14 (latencia básica)

Las historias de usuario restantes pueden considerarse una versión a futuro o ser trabajadas si el tiempo de desarrollo lo permite.

Sugerencia de organización de sprints

Sprint	Semana	Objetivos	Hito Entregable
1	1-2	• Navegación 3D • Trigger NPC • UI básica	1. Responder UI a eventos de mouse y teclado. 2. Navegar por el mundo 3D

2	3-4	• Ingesta documentos • Base vectorial • Embeddings	1. En Backend, desplegadas las APIs para ingesta de documentos. 2. Actualizar los embeddings en la base de datos vectorial.
3	5-6	• Pipeline RAG completo • Integración API • Métricas de experiencia de usuario	1. RAG disponible para interactuar con usuarios, a través del chat y por audio. 2. RAG integrado con APIs de Backend. 3. Demo con usuarios reales, y obtener las métricas de UX.
4	7-8	• Métricas del producto • Optimización latencia • Seguridad y Robustez	1. Optimización del producto en base a métricas obtenidas de rendimiento y tiempos de respuesta. 2. Actualización frecuente de ventana de contexto, en base a preguntas y respuestas más recientes. 3. Seguridad incorporada y control de errores por servicios caídos, y activación en modo avión autónomo en base a caché de datos. 4. Monitoreo de alucinaciones y uso de barandillas (guardrails) para su control (previo a emitir respuestas a usuario). 5. Monitoreo de uso de tokens y control de costos.

***Tabla 3**. Secuencia de Sprints por Semana, Objetivos y e Hito Entregable*

5. Implementación de la propuesta

5.1 Planificación y estimación

El desarrollo del sistema se estructura bajo un enfoque ágil basado en el marco de trabajo Scrum, organizado en cuatro sprints de dos semanas cada uno, para un total de ocho semanas de desarrollo activo. Esta planificación iterativa e incremental permite validar progresivamente los componentes críticos del sistema, reduciendo el riesgo técnico mediante entregas parciales funcionales y ajustando el alcance en función del aprendizaje obtenido en cada ciclo.

Cada sprint tiene objetivos técnicos claramente delimitados: (1) construcción del entorno tridimensional base en Unreal Engine 5 e implementación de la interacción inicial con el NPC mediante texto; (2) desarrollo del pipeline de ingesta documental, generación de embeddings y almacenamiento en la base vectorial FAISS; (3) integración completa del pipeline RAG —incluyendo la lógica de recuperación híbrida BM25 + embeddings con fusión RRF y el módulo de generación CRAG— así como la comunicación bidireccional entre el frontend 3D y el backend FastAPI; y (4) optimización del rendimiento del sistema, fortalecimiento de la seguridad en la capa API, pruebas de robustez y preparación del entorno de demostración.

Dado que el proyecto se desarrolla en un contexto académico, no se contempla un presupuesto económico formal. No obstante, la selección deliberada de herramientas de código abierto —Ollama, FAISS, LangChain, FastAPI, entre otras— demuestra la viabilidad técnica del sistema bajo restricciones reales de costo, lo cual constituye en sí mismo un aporte metodológico relevante para contextos con recursos limitados.

5.2 Implementación

Arquitectura del Sistema

La arquitectura del sistema adopta un modelo cliente-servidor desacoplado que favorece la modularidad, la escalabilidad y la mantenibilidad del código. El componente frontend se desarrolla íntegramente en Unreal Engine 5 (UE5), aprovechando su motor de renderizado en tiempo real para ofrecer una experiencia inmersiva en un entorno tridimensional donde el usuario interactúa con un NPC mediante lenguaje natural. El backend se implementa con Python y FastAPI, exponiendo una API REST que actúa como intermediaria entre el entorno 3D y el motor de inteligencia artificial.

El pipeline RAG (Retrieval-Augmented Generation) constituye el núcleo cognitivo del sistema. Su función es transformar documentos no estructurados en conocimiento recuperable, mediante la generación de representaciones vectoriales densas (embeddings),

su almacenamiento en una base vectorial indexada y la recuperación contextual de fragmentos relevantes ante cada consulta del usuario. Sobre este resultado recuperado, el modelo de lenguaje genera una respuesta fundamentada, reduciendo significativamente la tasa de alucinaciones en comparación con modelos generativos sin grounding documental.

En cuanto a las decisiones tecnológicas adoptadas, se selecciona FAISS (Facebook AI Similarity Search) como motor de indexación vectorial, debido a su simplicidad de integración, su capacidad de ejecución completamente local y su eficiencia demostrada en prototipos académicos de escala media. Si bien alternativas como Qdrant o Weaviate ofrecen mayor escalabilidad y funcionalidades avanzadas de filtrado, FAISS permite una implementación directa sin overhead de infraestructura adicional, lo cual resulta coherente con el enfoque on-premise del proyecto.

El modelo de lenguaje se despliega mediante Ollama, utilizando variantes cuantizadas de modelos como LLaMA 3 o Mistral 7B. Esta decisión prioriza la ejecución local para eliminar la dependencia de servicios externos, garantizar la privacidad de los datos procesados y mantener latencias aceptables sin requerir conectividad a internet. Esta elección resulta especialmente pertinente en el contexto académico, donde el acceso sostenido a APIs de pago no es siempre viable.

El sistema integra además un mecanismo de recuperación híbrida que combina BM25 —búsqueda léxica basada en frecuencia de términos— con embeddings semánticos densos. La fusión de ambos rankings se realiza mediante Reciprocal Rank Fusion (RRF), técnica que ha demostrado superar consistentemente a los métodos de recuperación unimodal en benchmarks de question answering. Adicionalmente, se implementa un módulo CRAG (Corrective RAG) que evalúa la relevancia de los fragmentos recuperados antes de pasarlos al modelo generativo, activando un ciclo de autocorrección cuando la confianza de recuperación es baja.

5.3 Despliegue

El despliegue del sistema se realiza en modalidad on-premise, utilizando hardware local del equipo de desarrollo. Esta decisión elimina los costos asociados al uso de infraestructura en la nube y garantiza el control total sobre los datos procesados, aspecto especialmente relevante cuando el corpus documental podría contener información sensible o restringida.

Se definen tres entornos de ejecución diferenciados: desarrollo, integración continua y producción/demo. El entorno de desarrollo permite a cada integrante del equipo ejecutar el sistema de manera local mediante contenedores Docker, asegurando la reproducibilidad del entorno. La integración continua se gestiona a través de GitHub Actions, que ejecuta pruebas unitarias y de integración automatizadas ante cada push al repositorio principal, garantizando la estabilidad del código base. El entorno de producción se ejecuta sobre un

servidor equipado con GPU dedicada (NVIDIA), lo que permite correr los modelos LLaMA/Mistral con mayor eficiencia y menores tiempos de inferencia.

Se establece un plan de contingencias técnicas que cubre los escenarios de riesgo más probables: alta latencia en la inferencia del modelo (fallback a respuestas cacheadas o modelos más ligeros), fallos del backend FastAPI (reinicio automático mediante supervisor), corrupción o inconsistencia del índice vectorial FAISS (reconstrucción desde los documentos originales) y problemas de compatibilidad de drivers GPU (degradación controlada a CPU con advertencia al usuario). Para cada escenario se define un mecanismo de recuperación que garantiza la continuidad operativa del sistema durante las sesiones de demostración y validación.

Sistema backend

El backend es un sistema RAG (Retrieval-Augmented Generation) que permite hacer consultas inteligentes sobre documentos PDF. Combina:

- Búsqueda Semántica: Encuentra fragmentos relevantes usando embeddings
- LLM (Large Language Model): Genera respuestas coherentes con Groq API
- Gestión de Sesiones: Mantiene conversaciones contextualizadas por usuario
- Caché Distribuida: Optimiza performance con Redis

Problema que resuelve

Responder preguntas sobre documentos complejos sin perder contexto, manteniendo conversaciones coherentes por usuario.

Componentes prioncipales

1. API REST (FastAPI)

```
app/api/routes/
├── ingest.py       → Subir PDFs y procesarlos
├── query.py        → Hacer consultas y gestionar sesiones
```

Endpoints disponibles:

- `POST /api/ingest` - Subir y procesar PDFs
- `POST /api/queries` - Hacer una consulta
- `POST /api/sessions` - Crear sesión de usuario
- `GET /api/sessions/{id}` - Obtener información de sesión
- `GET /api/users/{user_id}/sessions` - Listar sesiones del usuario
- `GET /api/sessions/{id}/messages` - Ver historial de conversación
- `DELETE /api/sessions/{id}` - Eliminar sesión

2. Pipeline de Inyección (Procesamiento de PDFs)

```
PDF Subido
    ↓
[1] pdf_parser.py
    - Extrae texto página por página
    - Preserva estructura del documento
    ↓
[2] chunker.py
    - Divide en fragmentos de ~500 tokens
    - Mantiene contexto entre chunks
    - Almacena metadata: página, document_id, posición
    ↓
[3] embedder.py
    - Modelo: SentenceTransformer (all-MiniLM-L6-v2)
    - Convierte cada chunk a vector (384 dimensiones)
    ↓
[4] storage
    - Vectores → Qdrant (base de datos vectorial)
    - Metadata → SQLite/PostgreSQL
    - PDFs → Azure Blob Storage (opcional)
```

3. Base de Datos

SQLite/PostgreSQL (Metadata)

```
app/db/metadata_db.py
├── Documentos: id, nombre, ruta, fecha_carga
├── Chunks: id, document_id, contenido, metadata
└── Sesiones: id, usuario, fecha_creación, estado
```

Qdrant (Vector Store)

```
Colección: "rag_chunks"
├── Vector: 384 dimensiones (embedding)
├── Payload: {
│   "content": "texto del chunk",
│   "document_id": "...",
│   "page": 5,
│   "score": 0.95
│   }
```

Redis (Caché)

```
Keys:
- query_cache:{session_id}:{query_hash} → Resultado completo (TTL: 1h)
- session_cache:{session_id} → Historial reciente (TTL: 24h)
- rate_limit:{user_id} → Contador de requests (TTL: 1h)
```

4. Motor de Búsqueda Semántica

```
app/core/retriever.py

Flujo:
  Query del usuario
      ↓
  embedder.encode(query)
      ↓
  Qdrant busca los K vectores más similares
      ↓
  Retorna chunks relevantes con scores (0-1)
      ↓
  Re-ranking y filtrado
      ↓
  Top 5 chunks con contexto más relevante
```

Algoritmo: HNSW (Hierarchical Navigable Small World)

- Búsqueda: ~50ms en local, ~100ms en Qdrant Cloud
- Precisión: Típicamente 0.78-0.94 (BLEU score)

5. LLM Service (Groq API)

```
app/core/llm_service.py

Flujo:
  Chunks relevantes + Historial sesión + Query
      ↓
  Construir prompt contextualizado
      ↓
  Enviar a Groq API (LLaMA-2, Mistral, etc.)
      ↓
  Groq retorna respuesta en tiempo real
      ↓
  Post-procesar y guardar en sesión
```

Prompt Template (Instancia RAG)

```
Sistema: Eres un asistente experto. Responde basándote en el contexto.

Contexto (recursos encontrados en los documentos):
{chunks relevantes formateados}

Historial de conversación:
{últimos 5 mensajes}

Pregunta: {query del usuario}

Respuesta:
```

6. Gestión de Sesiones

```
app/models/session.py → Pydantic models
app/db/session_db.py → Persistencia en BD

Estructura:
Session {
  id: UUID
  user_id: str
  created_at: datetime
  messages: List[Message]
  metadata: {
    model: "groq",
    temperature: 0.7,
    top_k: 5
  }
}

Message {
  id: UUID
  session_id: UUID
  role: "user" | "assistant"
  content: str
  created_at: datetime
  retrieved_chunks: List[Chunk]  ← Trazabilidad
}
```

Ciclo de vida:

```
1. Usuario: POST /api/sessions → Crear sesión nueva
2. Usuario: POST /api/queries → Enviar pregunta
3. Sistema: Buscar en historial (últimos 5 msgs)
4. Sistema: Hacer query semántica
5. Sistema: Obtener respuesta de Groq
6. Sistema: Guardar en historial
7. Sistema: Retornar respuesta con metadata
```

Arquitectura del sistema backend

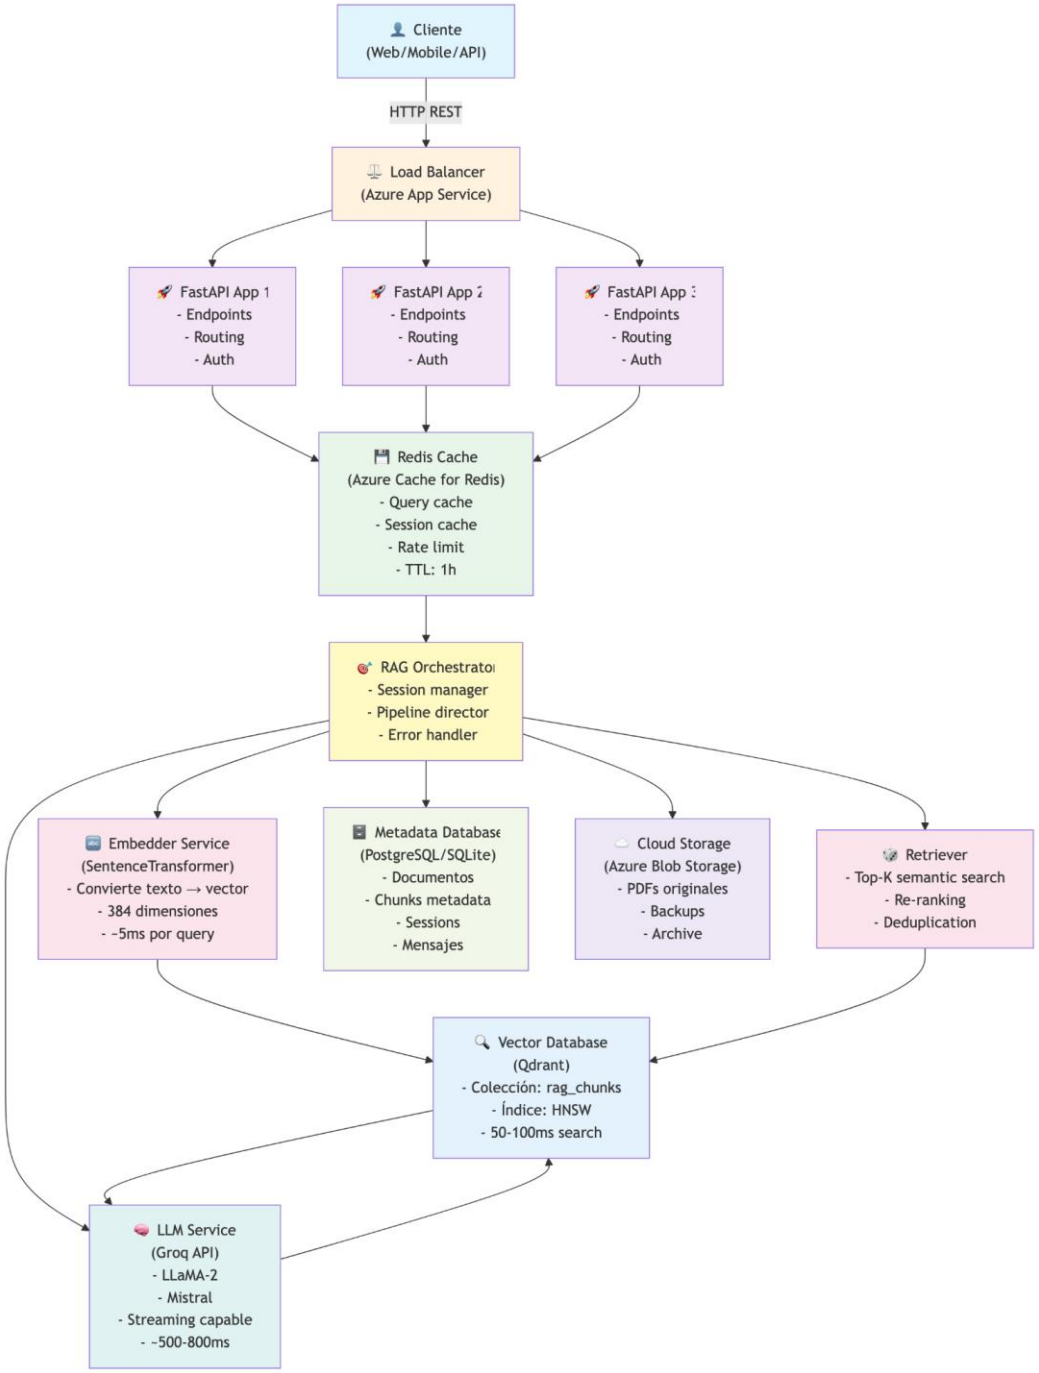

Imagen 19 *Arquitectura RAG escalable con balanceo de carga, servicios FastAPI, caché en Redis y orquestador que integra embeddings, base vectorial y LLM para respuestas eficientes y contextualizadas.*

Repositorio del código back-end: Link

5.4 Mantenimiento

La estrategia de mantenimiento del sistema contempla tres ejes fundamentales: la actualización continua de la base de conocimiento, la optimización iterativa del pipeline RAG

y la evolución del modelo de lenguaje conforme emerjan versiones más capaces o eficientes. Los documentos que conforman el corpus de conocimiento deben ser re-procesados periódicamente —o ante cambios sustanciales en el dominio— para garantizar que los embeddings reflejen con precisión el estado actual de la información.

El monitoreo del sistema se realiza mediante el seguimiento de métricas operacionales y de calidad, entre las que destacan: latencia de respuesta extremo a extremo (desde la consulta del usuario hasta la respuesta del NPC), precisión semántica de los fragmentos recuperados, tasa de alucinación estimada mediante el framework RAGAS, y puntuación de satisfacción del usuario obtenida en sesiones de validación. Estas métricas constituyen la base para decisiones de mejora continua y permiten documentar la evolución del sistema a lo largo del tiempo.

6. Validación y diseño experimental

6.1 Definición del MVP

El Producto Mínimo Viable (MVP) se define como la versión más reducida del sistema que permite obtener aprendizaje validado sobre sus hipótesis fundamentales. En el contexto de este proyecto, el MVP consiste en un entorno tridimensional funcional desarrollado en Unreal Engine 5, en el cual un NPC es capaz de recibir preguntas en lenguaje natural por parte del usuario y generar respuestas coherentes y fundamentadas documentalmente mediante el pipeline RAG implementado en el backend.

Este MVP permite validar simultáneamente dos dimensiones críticas del proyecto: la viabilidad técnica del sistema —es decir, que la arquitectura cliente-servidor desacoplada opera correctamente con latencias aceptables y respuestas pertinentes— y la aceptación por parte del usuario —esto es, que la interacción con un NPC inteligente en un entorno 3D resulta significativa, inmersiva y preferible frente a interfaces conversacionales tradicionales—. Ambas dimensiones son condición necesaria para justificar la escalabilidad del sistema hacia versiones más avanzadas.

6.2 Evolución del prototipo al MVP

Una vez validado el prototipo inicial, cuyo objetivo fue evaluar la experiencia de usuario en el entorno tridimensional sin implementación de lógica conversacional real, el desarrollo avanzó hacia la construcción del Producto Mínimo Viable (MVP). Esta fase supone una transición cualitativa significativa: el sistema deja de simular respuestas preconfiguradas para integrar de forma funcional el sistema de recuperación aumentada por generación (RAG) como núcleo del comportamiento conversacional del NPC. El frontend, desarrollado íntegramente en Unreal Engine 5, constituye la capa de presentación e interacción del sistema completo, y es el medio a través del cual el usuario percibe, evalúa y responde a la inteligencia artificial subyacente.

6.3 MVP Evaluación del RAG al back-end

Para ello se implementó una solución basada en el framework RAGAS para evaluar las métricas usando un juez LLM auditor automatizado, en base a librerías de LangChain, Ollama y el LLM con modelo llama3.1:8b (modelo open source). Y la aplicación web creada con Streamlit para poder recuperar la información necesaria para obtener las siguientes métricas.

Las métricas se clasificaron en 3 categorías.

6.3.1 Métricas de Generación

Fidelidad (Faithfulness):

Mide qué tanto la respuesta de la IA se mantiene fiel exclusivamente a los documentos recuperados.

- **Qué evalúa:** ¿La IA inventó algo (alucinación)? ¿Dijo algo que no estaba en el texto?
- **Cálculo ideal:** Se divide la respuesta en afirmaciones individuales y se verifica si cada una puede ser respaldada por el contexto proporcionado.

Relevancia de la Respuesta (Answer Relevance)

Mide qué tan pertinente es la respuesta para la pregunta del usuario.

- **Qué evalúa:** ¿La IA respondió realmente lo que se le preguntó?
- **Nota:** No evalúa si la información es cierta, sino si la respuesta "va al grano". Una respuesta puede ser muy relevante pero estar equivocada si el contexto era malo.

6.3.2 Métricas de Recuperación (Contexto)

Estas evalúan la calidad de los documentos que el sistema extrajo de tu base de datos vectorial.

Precisión del Contexto (Context Precision)

Mide si los fragmentos de información (chunks) relevantes aparecen en los primeros lugares de los resultados.

- **Qué evalúa:** El orden y la calidad del ranking. Si el sistema recupera 5 documentos, pero el único que tiene la respuesta está en el puesto 5, la precisión es menor que si estuviera en el puesto 1.

Recuperación del Contexto (Context Recall)

Mide si el sistema fue capaz de encontrar **toda** la información necesaria para responder la pregunta, basándose en una "verdad fundamental" (ground truth).

- **Qué evalúa:** ¿Se quedó información importante fuera? Si la respuesta requería datos de dos documentos y el sistema solo trajo uno, el *Recall* será bajo.

6.3.3 Métricas de Resultado Final

Corrección de Respuesta (Answer Correctness)

Esta es la métrica "maestra" que compara la respuesta generada por el sistema con una respuesta de referencia (la respuesta correcta ideal escrita por un humano).

- **Qué evalúa:** Combina la exactitud semántica (que signifique lo mismo) y la exactitud factual (que los datos coincidan).
- **Diferencia con Fidelidad:** Mientras que la Fidelidad mira si la IA fue honesta con el contexto, la Corrección mira si la respuesta final es simplemente la "verdad".

6.3.4 Métricas Principales

Antes de continuar con métricas principales, cabe notar que las métricas anteriores serán evaluadas por un juez automatizado y las siguientes métricas son calculadas posteriormente.

Score General

Considera las siguientes métricas, haciendo un promedio de ellas.

$$ScoreGeneral = \frac{100}{n} \sum_{i=1}^{n} \mathrm{F}_i + \mathrm{RR}_i + \mathrm{PC}_i + \mathrm{RC}_i + \mathrm{CR}_i$$

Tasa de Alucinación

Para esta métrica, se considera una lógica de evaluación más compleja, ya que un LLM no es un simple buscador de textos, entonces las respuestas a veces no contienen información usando palabras de la pregunta, y entonces hay que reevaluar en esos casos si la respuesta trae información valiosa para cumplir con lo esperado por el usuario.

Es por ello que se ha definido un árbol de decisión para poder evaluar como alucinación la forma de dar la respuesta.

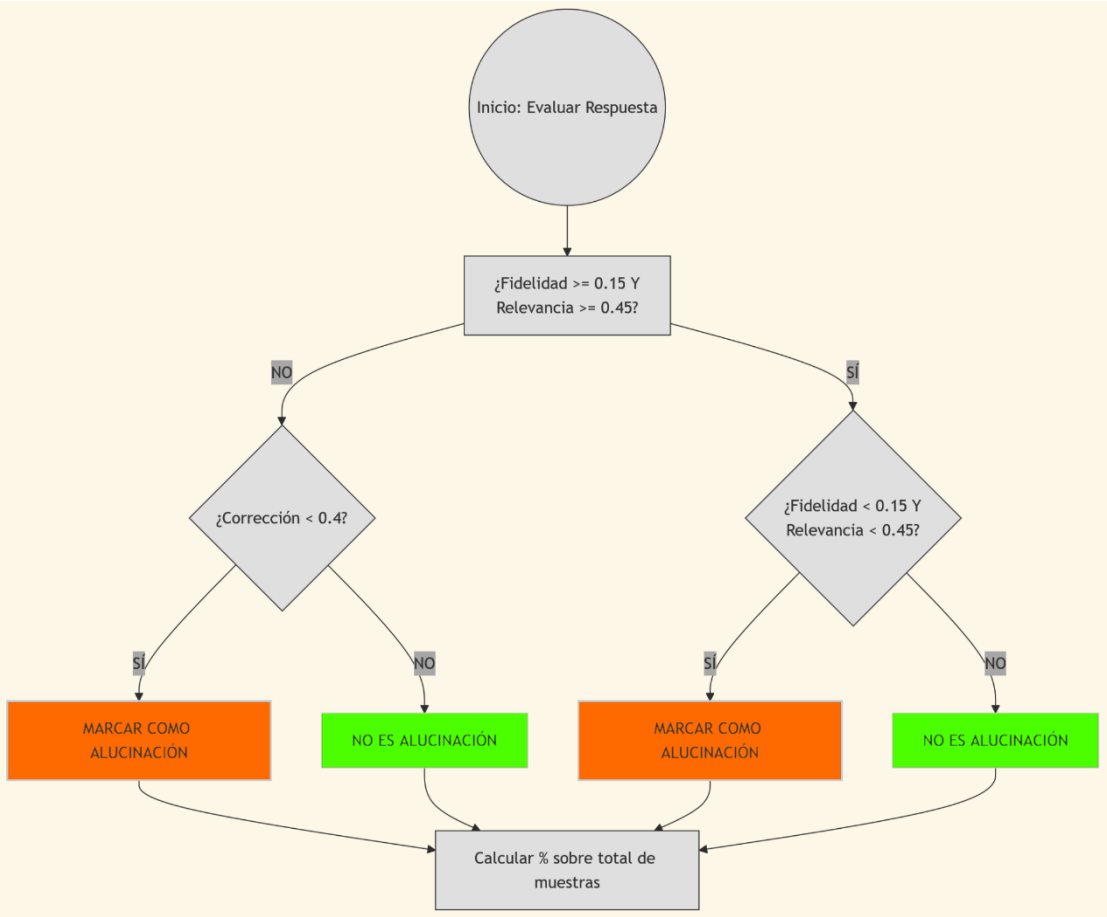

Imagen 20 *Árbol de decisión para calcular la métrica de Tasa de Alucinación*

Los umbrales de valores promedio que se propusieron alcanzar para cada métrica son los siguientes:

- Fidelidad: >= 0.15
- Relevancia: >= 0.45
- Precisión del Contexto: >= 0.50
- Recuperación del Contexto: >= 0.40
- Corrección de Respuesta: >= 0.40
- Score General: > 50%
- Tasa de Alucinación: <= 10%
- Tiempo de Respuesta: <= 1.5 segundos

Implementación de Juez Evaluador

Streamlit: Es el framework principal usado para construir toda la interfaz de usuario web. Permite crear rápidamente aplicaciones interactivas con Python. Se encarga de las vistas de chat, los botones, los formularios para subir archivos y la visualización de los resultados de la auditoría.

Ragas: Es el framework de evaluación especializado para sistemas RAG. Su función es medir la calidad de las respuestas del IA usando métricas clave.

Ollama y LangChain:

Ollama se usa para ejecutar modelos de lenguaje grandes (LLMs) de forma local en tu máquina. En este caso, se usa un modelo como llama3.1:8b para que actúe como un "juez" imparcial que califica las respuestas según los criterios de Ragas.

LangChain (langchain_ollama) actúa como un conector que permite a Ragas comunicarse fácilmente con el modelo que corre en Ollama.

Fase de entrada

Los datos de entrada para la evaluación fueron los siguientes:

1. Archivo **JSON ground truth** con respuesta esperada. Archivo
2. **Pregunta realizada** (prompt)
3. Respuesta obtenida, proveniente del LLM.
4. Contextos (embeddings), los textos top ordenados por prioridad por el LLM previo a su generación de respuesta.

Esta información fue recogida iterando para 5 preguntas.

Fase de evaluación

Luego al procesar la información por el Juez Automatizado, el procesó tardó alrededor de 9 minutos.

Los resultados fueron los siguientes:

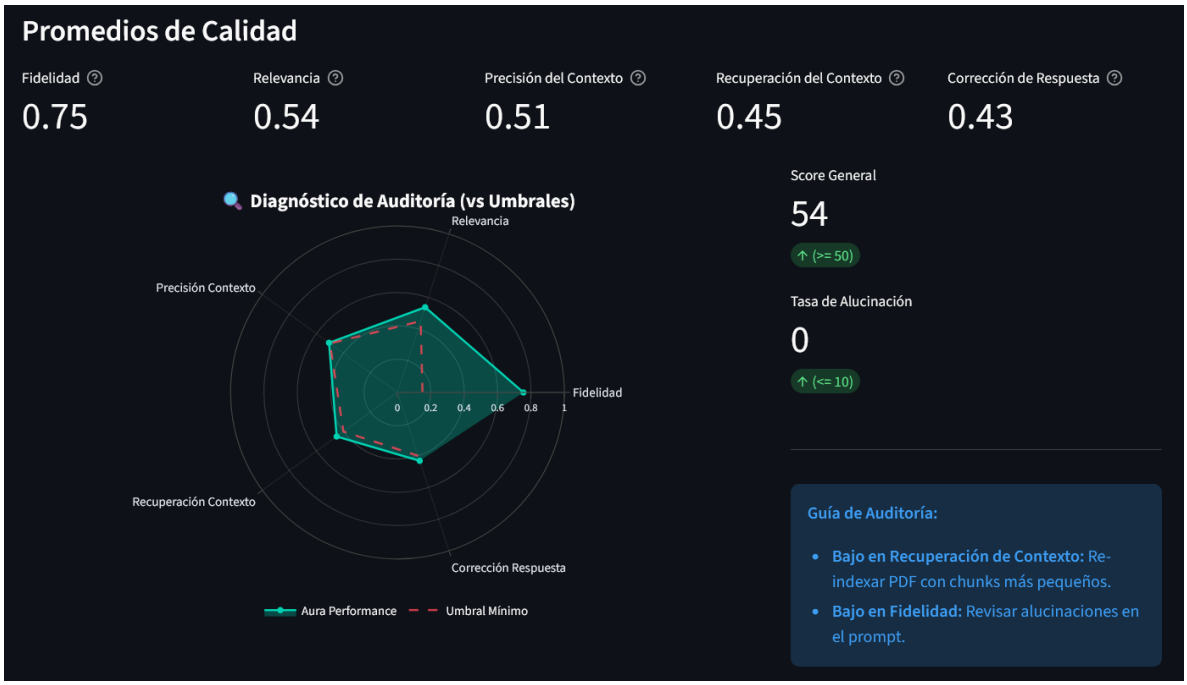

Imagen 21 *Métricas de Calidad de la respuesta del LLM backend, extraído desde aplicación Streamlit*

Promedios de Calidad:

- Fidelidad: 0.75 (>= 0.15)
- Relevancia: 0.54 (>= 0.45)
- Precisión del Contexto: 0.51 (>= 0.50)
- Recuperación del Contexto: 0.45 (>= 0.40)
- Corrección de Respuesta: 0.43 (>= 0.40)

Score General: 54% (>= 50 %)

Tasa de Alucinación: 0% (<= 10 %)

Imagen 22 *Métricas de Calidad con sus umbrales, extraído desde aplicación Streamlit (pdf exportado)*

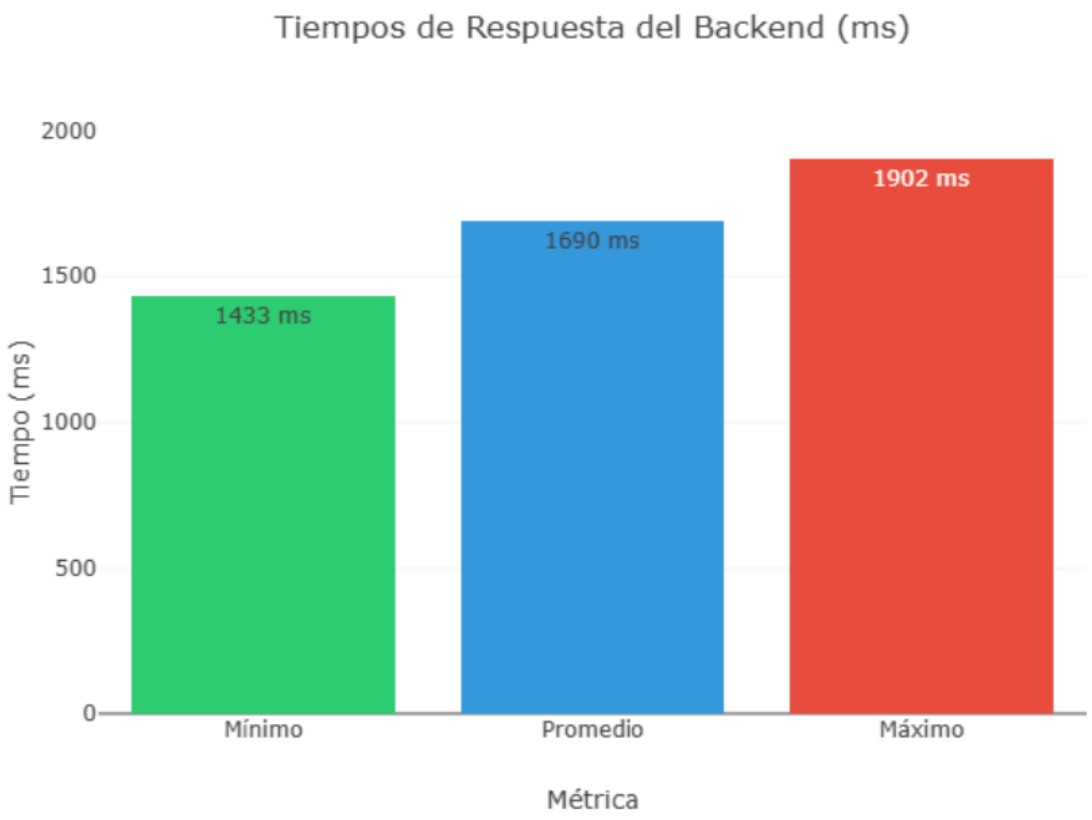

Análisis de Tiempos de Respuesta:

- Tiempo Promedio: 1690ms (> 1500 ms)
- Tiempo Mínimo: 1433 ms
- Tiempo Máximo: 1902 ms

Imagen 23 *Métricas Técnicas de Tiempo de Respuesta, extraído desde aplicación Streamlit (pdf exportado)*

Reporte de Auditoría RAG - Proyecto RAG backend

Fecha: 2026-04-15 20:20

Pregunta	Fidelidad	Relevancia	Alucinación	Prec. Contexto	Recup. Contexto	Correc. Resp.	Tpo. Resp. (ms)
quiero comprar un repelente y dieciseis ..	0.86	0.68	False	0.00	0.00	0.41	1856
en qué horario puedo encontrar a Marvin ..	0.89	0.75	False	0.70	0.00	0.27	1806
¿Qué tipo de preguntas te hizo Mila?	0.75	0.79	False	1.00	1.00	0.48	1902
Quién duerme en el taller de Marvin con ..	0.50	0.47	False	0.83	0.25	0.57	1450
Hay comunicación cuando hay tormentas?	0.78	0.00	False	0.00	1.00	0.43	1433

Imagen 24 *Métricas Técnicas En Detalle por cada evento de pregunta y respuesta, extraído desde aplicación Streamlit (pdf exportado)*

Resumen del análisis de métricas cuantitativas

Se lograron las métricas principales de Score General (54% >= 50%) y Tasa de Alucinación (0% <= 10%) que estén el rango esperado, solo el tiempo de respuesta está ligeramente fuera de su rango y este puede deberse a latencias de la red, y otros factores que no se pueden controlar.

Es un LLM que puede dar respuestas coherentes y no logró alucinar, por lo tanto es factible integrarlo al entorno FRONT tridimensional.

6.4 Entorno tridimensional final

El entorno tridimensional del MVP mantiene y amplía la propuesta escénica definida en la fase de prototipado. El mapa comprende un territorio rural costero con relieve variado, compuesto por zonas montañosas, bosques de coníferas, campos de cultivo, edificaciones de arquitectura mediterránea y una carretera sinuosa que articula el recorrido del jugador a lo largo del escenario.

La vista aérea del mapa, visible en la Imagen 1, permite apreciar la disposición general del espacio jugable y la distribución de los distintos puntos de interés, entre los cuales destaca de forma central la zona de actividad del NPC inteligente. El mapa incorpora además una masa de agua en el extremo este y una red de caminos que orientan naturalmente la navegación del jugador sin necesidad de indicaciones explícitas.

***Imagen 25**. Vista aérea general del mapa 3D mostrando zonas explorables, carretera, edificaciones y área central donde se localiza el NPC. Fuente: Elaboración propia en Unreal Engine 5.*

Desde la perspectiva del jugador en primera persona, el escenario genera una experiencia de inmersión coherente con la narrativa del mundo ficticio establecida para el NPC. La Imagen 2 ilustra una vista a nivel de jugador de las edificaciones rurales del rancho, donde se aprecia la calidad visual del entorno y la escala del escenario. El diseño espacial delimita implícitamente las zonas explorables mediante elementos propios del entorno como montañas, vegetación densa y accidentes del terreno, sin recurrir aún a barreras artificiales, lo que contribuye a preservar la inmersión.

***Imagen 26.** Vista en perspectiva del jugador mostrando las edificaciones del rancho y el entorno rural del mapa. Fuente: Elaboración propia en Unreal Engine 5.*

La zona específica donde se localiza Marvin, el vendedor ambulante robótico, presenta una ambientación detallada que incluye mesas de trabajo con engranajes y cajas metálicas, una estructura de toldo improvisada, efectos de partículas que simulan chispas eléctricas y humo, y una gran chimenea industrial adosada a la roca (Imagen 3). Esta carga narrativa visual no es meramente estética: cumple la función de contextualizar al NPC dentro del universo de significado que el sistema RAG debe ser capaz de referenciar durante la conversación, reforzando la coherencia entre el agente inteligente y su representación física en el mundo tridimensional.

Imagen 26. *Vista final de la zona del NPC Marvin mostrando el puesto de venta con elementos narrativos: engranajes, cajas, toldo, chimenea industrial y efectos de partículas. Fuente: Elaboración propia en Unreal Engine 5.*

6.5 Sistema de interacción con el NPC

La integración del RAG en el MVP requirió el diseño de un sistema de interacción en dos fases claramente diferenciadas: la detección de proximidad y la interfaz conversacional. Ambas fueron implementadas directamente en Unreal Engine 5 mediante el sistema de Blueprints, sin dependencia de motores de interfaz externos.

6.6 Fase de activación y detección

Cuando el jugador entra en el radio de interacción definido alrededor del NPC, el sistema detecta la colisión con el volumen esférico asociado al personaje y despliega una notificación visual contextual sobre la escena tridimensional. Como se observa en la Imagen 4, dicha notificación muestra el mensaje "Presiona 'F' para hablar con Marvin", comunicando al usuario de forma inequívoca la disponibilidad de interacción sin interrumpir la experiencia de exploración. Este mecanismo sigue convenciones de diseño de interacción ampliamente adoptadas en la industria del videojuego, lo que reduce la curva de aprendizaje del usuario y minimiza la fricción en el acceso al sistema conversacional.

***Imagen 27**. Notificación contextual desplegada al entrar en el radio de interacción del NPC, indicando al jugador la tecla de activación. Fuente: Elaboración propia en Unreal Engine 5.*

6.7 Fase Conversacional e interfaz gráfica

Al activar la interacción mediante la tecla correspondiente, el sistema despliega la interfaz gráfica de conversación visible en la Imagen 5. Esta interfaz ha sido diseñada con una estética coherente con la temática futurista del NPC: tipografía y elementos en verde fosforescente sobre fondo oscuro semitransparente, superponiéndose sobre el entorno 3D sin ocultarlo por completo, lo que mantiene el sentido de presencia en el mundo virtual.

La interfaz se estructura en tres componentes funcionales diferenciados. En la zona superior, un encabezado identifica el contexto de la interacción mediante el texto "Estás hablando con el vendedor ambulante 'Marvin'", anclando la identidad del agente y el rol que desempeña dentro del sistema. En la zona central, un panel de visualización muestra el nombre del interlocutor en tipografía destacada junto al mensaje generado por el sistema RAG, que en el estado inicial de la sesión corresponde al saludo de bienvenida "Hola aventurero, qué te trae por aquí", estableciendo el tono conversacional del agente. En la zona inferior, un campo de entrada de texto con el marcador de posición "Introduce tu pregunta..." permite al usuario formular consultas en lenguaje natural, las cuales son enviadas al backend mediante el botón "Enviar". Adicionalmente, el botón "End Conversation" permite al jugador cerrar la interfaz y retomar la exploración del entorno en cualquier momento.

Imagen 28. *Interfaz gráfica de conversación con el NPC Marvin, mostrando encabezado de contexto, panel de respuesta del agente y campo de entrada de texto para el usuario. Fuente: Elaboración propia en Unreal Engine 5.*

6.8 Integración frontend-backend: flujo de comunicación con el sistema RAG

Desde el punto de vista arquitectónico, el frontend en Unreal Engine 5 actúa como cliente del sistema RAG a través de un flujo de comunicación HTTP implementado mediante Blueprints y el plugin VaRest, que provee soporte nativo para solicitudes REST dentro del entorno de Unreal Engine. El flujo completo de integración se representa en la Imagen 6 y puede describirse en las siguientes etapas.

En primer lugar, cuando el usuario introduce una consulta y presiona el botón de envío, el sistema construye un objeto JSON mediante el nodo Make Json, que encapsula tres parámetros: el texto de la pregunta (Question), un identificador de sesión (Session Id) que permite mantener el contexto conversacional entre turnos, y el parámetro Top K con valor 5.0, que determina el número de fragmentos recuperados por el sistema RAG en la fase de búsqueda semántica.

A continuación, el sistema instancia una solicitud HTTP de tipo POST mediante el nodo Construct Json Request del subsistema VaRest, asocia el objeto JSON construido mediante Set Request Object, y configura el endpoint de destino mediante Process URL, apuntando a la dirección local del servidor backend en http://localhost:8000/api/queries. La solicitud se despacha de forma asíncrona y el evento Bind Event to On Request Complete registra una función de callback que se ejecutará al recibir la respuesta.

Una vez completada la solicitud, el evento personalizado LLMResponse_2 es invocado con el objeto de respuesta como parámetro. El sistema extrae el cuerpo de la respuesta mediante Get Response Object, accede al campo answer del JSON devuelto a través de Get String Field, convierte el valor a tipo texto mediante To Text y actualiza dinámicamente el panel de visualización de la interfaz mediante el nodo Update Dialog Text del widget WB LLMDialogue.

Finalmente, el campo de entrada es reactivado mediante Set User Input Read Only, permitiendo al usuario formular la siguiente consulta y completando así el ciclo de interacción.

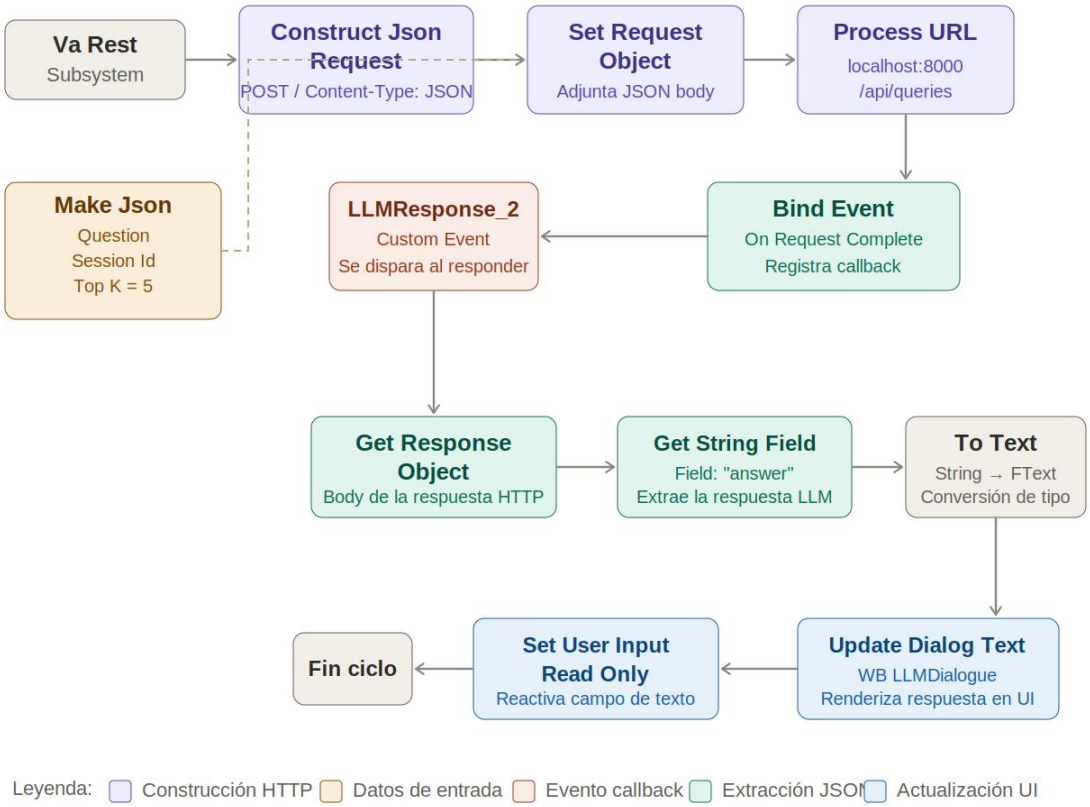

Imagen 29. *Flujo de Blueprint en Unreal Engine 5 que implementa la comunicación HTTP entre el frontend y el backend RAG, incluyendo construcción del JSON, envío de la solicitud POST, gestión del callback y actualización de la interfaz. Fuente: Elaboración propia en Unreal Engine 5.*

Este diseño desacoplado entre frontend y backend permite que ambas capas evolucionen de forma independiente, facilitando iteraciones sobre la interfaz de usuario sin afectar la lógica del modelo de lenguaje, y viceversa. El uso del parámetro Session Id en cada solicitud garantiza además que el sistema RAG pueda mantener coherencia contextual a lo largo de una sesión conversacional, aspecto crítico para la credibilidad del agente como interlocutor inteligente.

Repositorio del ejecutable UI: Link

6.9 Consideraciones de diseño de experiencia de usuario

El diseño del frontend del MVP incorpora decisiones orientadas a maximizar la coherencia entre la experiencia de juego y la interacción con el agente conversacional. La elección de mantener el entorno tridimensional visible durante la conversación, en lugar de transicionar a una pantalla de diálogo independiente, responde a la hipótesis de que la inmersión espacial

contribuye positivamente a la percepción del NPC como entidad integrada en el mundo, en lugar de como una interfaz de consulta descontextualizada.

Asimismo, la identidad visual de la interfaz, coherente con la estética robótica y retrofuturista de Marvin, refuerza la consistencia narrativa del sistema y puede influir positivamente en la disposición del usuario a mantener interacciones conversacionales prolongadas. La implementación del mecanismo de activación por proximidad, en lugar de un acceso directo desde el menú, obliga al usuario a desplazarse físicamente hasta el NPC, reproduciendo una dinámica social análoga a la interacción real y potenciando el sentido de agencia en el entorno virtual.

La totalidad del desarrollo frontend descrito fue implementada en Unreal Engine 5, aprovechando el sistema nativo de widgets UMG (Unreal Motion Graphics) para la construcción de todos los elementos de la interfaz gráfica de usuario, y el sistema de Blueprints para la lógica de interacción, detección de proximidad y comunicación con el backend. Estos aspectos serán objeto de evaluación empírica en la fase de pruebas con usuarios, donde se medirán variables como la intuitividad del sistema, el nivel de inmersión percibida y el interés del jugador en mantener conversaciones prolongadas con el agente.

6.10 Ciclo de Construir-Medir-Aprender (Lean Startup)

La estrategia de validación del sistema se fundamenta en la metodología LEAN Startup, particularmente en su ciclo iterativo Construir-Medir-Aprender (Build-Measure-Learn). Este enfoque permite someter las hipótesis técnicas y de experiencia de usuario a pruebas empíricas controladas, en lugar de asumir su validez a priori, lo que reduce el riesgo de desarrollar funcionalidades que no generen valor real.

En la fase Construir, se desarrolla el MVP descrito anteriormente, priorizando la funcionalidad nuclear sobre características secundarias. En la fase Medir, se recopilan datos cuantitativos y cualitativos durante sesiones de usuario controladas, utilizando métricas previamente definidas que cubren tanto el desempeño técnico del sistema como la percepción subjetiva del usuario. En la fase Aprender, los resultados obtenidos se contrastan con los criterios de aceptación establecidos, generando decisiones informadas sobre iteraciones de mejora: ajuste de parámetros del pipeline RAG, refinamiento de los prompts del sistema, optimización de la recuperación híbrida o modificaciones en la interfaz 3D. Este ciclo se ejecuta de forma iterativa, con al menos dos rondas de validación programadas durante el desarrollo del proyecto.

6.11 Medir Criterios de validación final

Se definen criterios de validación tanto cuantitativos como cualitativos, organizados en dos dimensiones: desempeño técnico del sistema y experiencia del usuario.

Desde la perspectiva técnica, se evalúan las siguientes métricas mediante el framework RAGAS (Retrieval-Augmented Generation Assessment):

- Faithfulness: mide la proporción de afirmaciones en la respuesta generada que pueden ser verificadas en el contexto recuperado. Valor objetivo ≥ 0.80.
- Answer Relevancy: evalúa el grado en que la respuesta generada es pertinente respecto a la pregunta formulada. Valor objetivo ≥ 0.75.
- Context Precision: determina qué proporción del contexto recuperado es realmente relevante para responder la consulta. Valor objetivo ≥ 0.70.
- Latencia de respuesta extremo a extremo: tiempo transcurrido desde que el usuario formula la pregunta hasta que el NPC genera la respuesta completa. Valor objetivo ≤ 5 segundos en condiciones normales de operación.

Desde la perspectiva de experiencia de usuario, se aplica una encuesta post-sesión basada en escalas Likert de cinco puntos, evaluando las siguientes dimensiones:

- Percepción de inmersión: grado en que el entorno 3D y el NPC generan una sensación de presencia y naturalidad en la interacción.
- Satisfacción con las respuestas: valoración subjetiva de la pertinencia, claridad y utilidad de las respuestas del NPC.
- Preferencia frente a interfaces tradicionales: comparación directa con chatbots conversacionales convencionales (sin entorno 3D).

6.12 Diseño de la sesión de validación

Las sesiones de validación se diseñan como experimentos controlados de usuario, estructurados en tres fases secuenciales. En la fase de introducción, los participantes reciben una breve explicación del sistema y sus objetivos, sin revelar detalles técnicos que puedan sesgar su percepción. En la fase de interacción, cada usuario dispone de un período libre de exploración (aproximadamente 15 minutos) durante el cual formula preguntas al NPC sobre un dominio documental predefinido, siguiendo un protocolo de tareas estructuradas que asegura la cobertura de distintos tipos de consultas (factual, inferencial, comparativa). Finalmente, en la fase de evaluación, los participantes completan la encuesta Likert y participan en una breve entrevista semiestructurada para capturar percepciones no contempladas en los instrumentos cuantitativos.

Se contempla la participación de un mínimo de diez usuarios, seleccionados con criterios de heterogeneidad en términos de familiaridad con entornos 3D y con sistemas de inteligencia artificial conversacional, con el fin de obtener una muestra representativa de distintos perfiles de usuario. Los datos recopilados se analizan de forma combinada: las métricas RAGAS se evalúan de manera automática mediante el pipeline de evaluación integrado, mientras que las respuestas de la encuesta se procesan mediante estadística descriptiva e inferencial básica. Los hallazgos de ambas fuentes se triangulan para obtener una visión integral del desempeño del sistema.

7. Conclusiones y trabajo futuro

7.1 Resumen del resultado

El proyecto demuestra la viabilidad técnica de integrar un NPC conversacional basado en RAG dentro de un entorno tridimensional desarrollado en Unreal Engine 5. La arquitectura cliente-servidor implementada logra conectar el frontend del juego con el backend de inteligencia artificial de forma funcional: el personaje responde en tiempo real a las preguntas del jugador, las respuestas se fundamentan en la base de conocimiento proporcionada y los tiempos de respuesta se mantienen dentro de márgenes aceptables para la experiencia interactiva.

La integración técnica entre Unreal Engine 5, la API de Groq, Qdrant y el sistema RAG funciona de forma satisfactoria y estable. Las respuestas del NPC muestran un buen nivel de fidelidad al documento de conocimiento, con escasa presencia de información inventada o fuera del contexto definido para el personaje.

7.2 Limitaciones identificadas

La limitación más notable observada durante las pruebas es de carácter expresivo: aunque Marvin responde con precisión, su tono resulta excesivamente formal y lógico, alejado de la personalidad desenfadada, excéntrica y cálida definida en el diseño del personaje. La causa más probable es que las instrucciones de rol en el prompt del sistema no son suficientemente específicas para guiar al modelo hacia ese registro conversacional, o que el modelo tiende a priorizar la precisión informativa sobre la coherencia de personalidad cuando ambos objetivos entran en tensión.

Una segunda limitación es la dependencia de servicios externos para la ejecución del sistema: actualmente el usuario debe tener Docker activo y los servicios del backend en ejecución de forma independiente al juego, lo que dificulta la distribución y el uso fuera de un entorno de desarrollo.

7.3 Trabajo futuro

Las mejoras identificadas se organizan por prioridad e impacto:

A corto plazo, el ajuste más urgente es la mejora de la personalidad del NPC. Esto implica refinar el prompt de sistema con instrucciones más detalladas sobre el tono, el vocabulario y las expresiones características de Marvin, e incorporar ejemplos de conversación en el few-shot para que el modelo adopte el registro esperado. También se propone enriquecer las animaciones del personaje con estados reactivos —gestos de saludo, reacciones al silencio, movimientos de trabajo en el taller— que refuercen la ilusión de presencia sin depender exclusivamente del texto generado.

A medio plazo, el objetivo más relevante es empaquetar el sistema completo en un único ejecutable distribuible, eliminando la dependencia de Docker y de servicios externos que el usuario deba gestionar manualmente. Esto requeriría integrar el backend directamente en el pipeline de empaquetado de Unreal Engine o implementar un proceso de arranque automático de los servicios necesarios al iniciar el juego. Asimismo, se propone añadir jugabilidad al entorno 3D: misiones o tareas que el jugador pueda completar usando la información obtenida del NPC, cerrando el ciclo entre la conversación y la acción dentro del mundo virtual.

A largo plazo, se contempla integrar síntesis de voz para que Marvin hable en lugar de mostrar texto, lo que elevaría significativamente el nivel de inmersión. En paralelo, se podría implementar memoria persistente de conversación para que el NPC recuerde interacciones anteriores con el mismo usuario y evolucione su relación con él a lo largo de múltiples sesiones. Finalmente, la incorporación de más NPCs con bases de conocimiento y personalidades diferenciadas permitiría construir un ecosistema narrativo más rico, en el que los personajes puedan referenciarse entre sí y ofrecer perspectivas distintas sobre el mismo mundo.

7.4 Reflexión final

Este proyecto demuestra que la integración de IA conversacional contextualizada en entornos 3D interactivos es técnicamente alcanzable con tecnologías de código abierto y sin infraestructura de alto coste. El resultado más significativo no es únicamente que el sistema funciona, sino que lo hace de forma coherente con su base de conocimiento, lo que valida el enfoque RAG como mecanismo de control narrativo para NPCs. Los aspectos pendientes —principalmente la naturalidad expresiva y la distribución autónoma— son problemas de ajuste y empaquetado, no limitaciones arquitectónicas, lo que sitúa al proyecto en una posición sólida para iteraciones futuras.

Referencias

Selvaraju, H., et al. (2024). Empowering human-like non-player character interactions in virtual reality through large language models. PJST, 7(2), Article 003. https://doi.org/10.61762/pjstvol7iss2art003

Liang, Y., et al. (2023). Tachikuma: Understanding complex interactions with multi-character and novel objects by large language models. arXiv preprint arXiv:2307.12573v1. https://arxiv.org/abs/2307.12573v1

Zhu, H. (2023). MetaAID 2.5: A secure framework for developing metaverse applications via large language models. Journal of IEEE. arXiv preprint arXiv:2312.14480v1. https://arxiv.org/abs/2312.14480v1

Buongiorno, S., et al. (2024). PANGEA: Procedural artificial narrative using generative AI for turn-based, role-playing video games. arXiv preprint arXiv:2404.19721v3. https://arxiv.org/abs/2404.19721v3

Buldu, K. B., et al. (2025). CUIfy the XR: An open-source package to embed LLM-powered conversational agents in XR. arXiv preprint arXiv:2411.04671v3. https://arxiv.org/abs/2411.04671v3

Yu, P., et al. (2025). RPGBENCH: Evaluating large language models as role-playing game engines. arXiv preprint arXiv:2502.00595v1. https://arxiv.org/abs/2502.00595v1

Chen, J., et al. (2025). LLMER: Crafting interactive extended reality worlds with JSON data generated by large language models. arXiv preprint arXiv:2502.02441v1. https://arxiv.org/abs/2502.02441v1

Brito, I. A., et al. (2025). Integrating personality into digital humans: A review of LLM-driven approaches for virtual reality. arXiv preprint arXiv:2503.16457v1. https://arxiv.org/abs/2503.16457v1

Song, L. (2025). LLM-driven NPCs: Cross-platform dialogue system for games and social platforms. arXiv preprint arXiv:2504.13928v1. https://arxiv.org/abs/2504.13928v1

Shiomi, K., et al. (2025). Tricking LLM-based NPCs into spilling secrets. arXiv preprint arXiv:2508.19288v1. https://arxiv.org/abs/2508.19288v1

Liu, Z., Agrawal, P., Singhal, S., Madaan, V., Kumar, M., & Verma, P. (2025). LPITutor: an LLM based personalized intelligent tutoring system using RAG and prompt engineering. PeerJ Computer Science, 11. https://doi.org/10.7717/peerj-cs.2991

Nouraei, F., Yong, Z., & Bickmore, T. (2025). HealthDial: A No-Code LLM-Assisted Dialogue Authoring Tool for Healthcare Virtual Agents. ArXiv, abs/2510.15898. https://doi.org/10.48550/arxiv.2510.15898

Narajeenron, K., Chintakovid, T., Phutrakool, P., Ritsamdang, J., Viriyopase, A., Musikatavorn, K., Srikasem, S., Boonbumrong, N., Jaipang, C., Seephom, S., Susantitapong, K., Chaichanawongsaroj, N., Khongwirotphan, S., Suayod, S., Sunpawut, P., Pavavimol, T., Kheawwan, P., Thanomlikhit, C., Rojnawee, S., Tippayamontri, T., Dhanakoses, K., Chanchaochai, N., Jitwiriyanont, S., Sahapattana, N., Khowinthaseth, S., Chu, O., Sarachana, T., & Worasilchai, N. (2025). Enhancing

Team Strategies and Tools to Enhance Performance and Patient Safety Performance Through Medical Movies, Massive Open Online Courses, and 3D Virtual Simulation–Based Interprofessional

Hou, C., Yu, H., Anas, J., Liu, J., & Ong, Y. (2025). MazeMate: An LLM-Powered Chatbot to Support Computational Thinking in Gamified Programming Learning. **. Amithasagaran, A., Dakshit, S., Suryadevara, B., & Stockton, L. (2025). CLiVR: Conversational Learning System in Virtual Reality with AI-Powered Patients. ArXiv, abs/2510.19031. https://doi.org/10.48550/arxiv.2510.19031

Hajji, M., Baha, T., Berka, A., Nacer, H., Aouifi, H., & Es-Saady, Y. (2025). An Architecture for Intelligent Tutoring in Virtual Reality: Integrating LLMs and Multimodal Interaction for Immersive Learning. *Information*. https://doi.org/10.3390/info16070556

Selvaraju, H., Arshad, N., Mukhlason, A., & Mahananto, F. (2024). EMPOWERING HUMAN-LIKE NON-PLAYER CHARACTER INTERACTIONS IN VIRTUAL REALITY THROUGH LARGE LANGUAGE MODELS. Platform A Journal of Science and Technology. https://doi.org/10.61762/pjstvol7iss2art003

Wang, M., Zhu, J., Hwang, G., Chang, S., Yang, Q., & Zhang, D. (2025). Boosting Student Engagement in STEM: Integrating Large Language Model-Based Virtual Agents Into Alternate Reality Games. Journal of Computer Assisted Learning. https://doi.org/10.1111/jcal.70139

Özkaya, S., Berrezueta-Guzman, S., & Wagner, S. (2025). How LLMs Are Shaping the Future of Virtual Reality. IEEE Access, 13, 193335-193355. https://doi.org/10.1109/access.2025.3631594

Christiansen, F., Hollensberg, L., Jensen, N., Julsgaard, K., Jespersen, K., & Nikolov, I. (2024). Exploring Presence in Interactions with LLM-Driven NPCs: A Comparative Study of Speech Recognition and Dialogue Options. Proceedings of the 30th ACM Symposium on Virtual Reality Software and Technology. https://doi.org/10.1145/3641825.3687716

Özdel, S., Sarpkaya, C., Bozkir, E., Gao, H., & Kasneci, E. (2025). Examining the Role of LLM-Driven Interactions on Attention and Cognitive Engagement in Virtual Classrooms. ArXiv, abs/2505.07377. https://doi.org/10.48550/arxiv.2505.07377

Bellucci, A., Jacucci, G., Trung, K., Das, P., Smirnov, S., Ahmed, I., & Lugrin, J. (2025). Immersive Tailoring of Embodied Agents Using Large Language Models. 2025 IEEE Conference Virtual Reality and 3D User Interfaces (VR), 392-400. https://doi.org/10.1109/vr59515.2025.00063

Izquierdo-Domenech, J., Linares-Pellicer, J., & Ferri-Molla, I. (2024). Virtual Reality and Language Models, a New Frontier in Learning. Int. J. Interact. Multim. Artif. Intell., 8, 46. https://doi.org/10.9781/ijimai.2024.02.007

Liu, Z., Zhu, Z., Zhu, L., Jiang, E., Hu, X., Peppler, K., & Ramani, K. (2024). ClassMeta: Designing Interactive Virtual Classmate to Promote VR Classroom Participation. Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3613904.3642947

Jiang, J., & Fryer, L. (2023). The effect of virtual reality learning on students' motivation: A scoping review. J. Comput. Assist. Learn., 40, 360-373. https://doi.org/10.1111/jcal.12885

Lau, K., Bozkir, E., Gao, H., & Kasneci, E. (2024). Evaluating Usability and Engagement of Large Language Models in Virtual Reality for Traditional Scottish Curling. ArXiv, abs/2408.09285. https://doi.org/10.1007/978-3-031-91572-7_11

Izquierdo-Domenech, J., Linares-Pellicer, J., & Ferri-Molla, I. (2024). Virtual Reality and Language Models, a New Frontier in Learning. *Int. J. Interact. Multim. Artif. Intell.*, 8, 46. https://doi.org/10.9781/ijimai.2024.02.007

Özdel, S., Sarpkaya, C., Bozkir, E., Gao, H., & Kasneci, E. (2025). Examining the Role of LLM-Driven Interactions on Attention and Cognitive Engagement in Virtual Classrooms. ArXiv, abs/2505.07377. https://doi.org/10.48550/arxiv.2505.07377

Chen, C., Hung, H., & Yeh, H. (2021). Virtual reality in problem-based learning contexts: Effects on the problem-solving performance, vocabulary acquisition and motivation of English language learners. *J. Comput. Assist. Learn.*, 37, 851-860. https://doi.org/10.1111/jcal.12528

Wang, M., Zhu, J., Hwang, G., Chang, S., Yang, Q., & Zhang, D. (2025). Boosting Student Engagement in STEM: Integrating Large Language Model-Based Virtual Agents Into Alternate Reality Games. *Journal of Computer Assisted Learning*. https://doi.org/10.1111/jcal.70139

Makransky, G., Borre-Gude, S., & Mayer, R. (2019). Motivational and cognitive benefits of training in immersive virtual reality based on multiple assessments. *J. Comput. Assist. Learn.*, 35, 691-707. https://doi.org/10.1111/jcal.12375

Hsu, L. (2024). Exploring EFL learners' acceptance and cognitive absorption at VR-Based language learning: A survey and experimental study. *Heliyon*, 10. https://doi.org/10.1016/j.heliyon.2024.e24863

Lau, K., Bozkir, E., Gao, H., & Kasneci, E. (2024). Evaluating Usability and Engagement of Large Language Models in Virtual Reality for Traditional Scottish Curling. *ArXiv*, abs/2408.09285. https://doi.org/10.1007/978-3-031-91572-7_11

Hung, C., Lin, Y., Yu, S., & Sun, J. (2023). Effects of AR- and VR-based wearables in teaching English: The application of an ARCS model-based learning design to improve elementary school students' learning motivation and performance. *J. Comput. Assist. Learn.*, 39, 1510-1527. https://doi.org/10.1111/jcal.12814

Lin, X., Li, B., Yao, Z., Yang, Z., & Zhang, M. (2024). The impact of virtual reality on student engagement in the classroom–a critical review of the literature. *Frontiers in Psychology*, 15. https://doi.org/10.3389/fpsyg.2024.1360574

Liu, Z., Zhu, Z., Zhu, L., Jiang, E., Hu, X., Peppler, K., & Ramani, K. (2024). ClassMeta: Designing Interactive Virtual Classmate to Promote VR Classroom Participation. *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. https://doi.org/10.1145/3613904.3642947

Seßler, K., Kepir, O., & Kasneci, E. (2024). Enhancing Student Motivation Through LLM-Powered Learning Environments - A Comparative Study. **, 156-162. https://doi.org/10.1007/978-3-031-72312-4_21

Hajji, M., Baha, T., Berka, A., Nacer, H., Aouifi, H., & Es-Saady, Y. (2025). An Architecture for Intelligent Tutoring in Virtual Reality: Integrating LLMs and Multimodal Interaction for Immersive Learning. *Information*. https://doi.org/10.3390/info16070556

Izquierdo-Domenech, J., Linares-Pellicer, J., & Ferri-Molla, I. (2024). Virtual Reality and Language Models, a New Frontier in Learning. *Int. J. Interact. Multim. Artif. Intell.*, 8, 46. https://doi.org/10.9781/ijimai.2024.02.007

Elfleet, M., & Chollet, M. (2024). Investigating the Impact of Multimodal Feedback on User-Perceived Latency and Immersion with LLM-Powered Embodied Conversational Agents in Virtual Reality. *Proceedings of the 24th ACM International Conference on Intelligent Virtual Agents*. https://doi.org/10.1145/3652988.3673965

Özdel, S., Sarpkaya, C., Bozkir, E., Gao, H., & Kasneci, E. (2025). Examining the Role of LLM-Driven Interactions on Attention and Cognitive Engagement in Virtual Classrooms. *ArXiv*, abs/2505.07377. https://doi.org/10.48550/arxiv.2505.07377

Hao, Z., Jiang, J., Yu, J., Liu, Z., & Zhang, Y. (2025). Student-AI Interaction in an LLM-Empowered Learning Environment: A Cluster Analysis of Engagement Profiles. **.

Wang, G., Deng, J., & Ali, S. (2025). Evaluating the Impact of AI-Powered Audiovisual Personalization on Learner Emotion, Focus, and Learning Outcomes. *ArXiv*, abs/2505.03033. https://doi.org/10.48550/arxiv.2505.03033

Hu, X., , D., He, F., Zhu, Z., Hsia, S., Zhu, C., Liu, Z., & Ramani, K. (2025). GesPrompt: Leveraging Co-Speech Gestures to Augment LLM-Based Interaction in Virtual Reality. *Proceedings of the 2025 ACM Designing Interactive Systems Conference*. https://doi.org/10.1145/3715336.3735769

Gao, X., Zhang, Z., Liu, T., & Fu, Y. (2025). OnlineMate: An LLM-Based Multi-Agent Companion System for Cognitive Support in Online Learning. *ArXiv*, abs/2509.14803. https://doi.org/10.48550/arxiv.2509.14803

Kühlem, K., Ehret, J., Kuhlen, T., & Bönsch, A. (2025). A Latency-Optimized LLM-based Multimodal Dialogue System for Embodied Conversational Agents in VR. *Proceedings of the 25th ACM International Conference on Intelligent Virtual Agents*. https://doi.org/10.1145/3717511.3749287

Pereira, A., & Mello, R. (2025). A Systematic Literature Review on Large Language Models Applications in Computer Programming Teaching Evaluation Process. *IEEE Access*, 13, 113449-113460. https://doi.org/10.1109/access.2025.3584060

Bonner, E., Lege, R., & Frazier, E. (2023). LARGE LANGUAGE MODEL-BASED ARTIFICIAL INTELLIGENCE IN THE LANGUAGE CLASSROOM: PRACTICAL IDEAS FOR TEACHING. *Teaching English With Technology*. https://doi.org/10.56297/bkam1691/wieo1749

Pereira, A., & Mello, R. (2025). A Systematic Literature Review on Large Language Models Applications in Computer Programming Teaching Evaluation Process. *IEEE Access*, 13, 113449-113460. https://doi.org/10.1109/access.2025.3584060

Shahzad, T., Mazhar, T., Tariq, M., Ahmad, W., Ouahada, K., & Hamam, H. (2025). A comprehensive review of large language models: issues and solutions in learning environments. Discover Sustainability, 6. https://doi.org/10.1007/s43621-025-00815-8

Balavar, M., Yang, W., Herbert, D., & Yeom, S. (2025). Enhancing tutoring systems by leveraging tailored promptings and domain knowledge with Large Language Models. *ArXiv*, abs/2505.02849. https://doi.org/10.48550/arxiv.2505.02849

Bonner, E., Lege, R., & Frazier, E. (2023). LARGE LANGUAGE MODEL-BASED ARTIFICIAL INTELLIGENCE IN THE LANGUAGE CLASSROOM: PRACTICAL IDEAS FOR TEACHING. *Teaching English With Technology*. https://doi.org/10.56297/bkam1691/wieo1749

Hiriyanna, S., & Zhao, W. (2025). Multi-Layered Framework for LLM Hallucination Mitigation in High-Stakes Applications: A Tutorial. *Comput.*, 14, 332. https://doi.org/10.3390/computers14080332

Lin, Z., Guan, S., Zhang, W., Zhang, H., Li, Y., & Zhang, H. (2024). Towards trustworthy LLMs: a review on debiasing and dehallucinating in large language models. *Artificial Intelligence Review*, 57. https://doi.org/10.1007/s10462-024-10896-y

Ayyamperumal, S., & Ge, L. (2024). Current state of LLM Risks and AI Guardrails. *ArXiv*, abs/2406.12934. https://doi.org/10.48550/arxiv.2406.12934

Dong, Y., Mu, R., Zhang, Y., Sun, S., Zhang, T., Wu, C., Jin, G., Qi, Y., Hu, J., Meng, J., Bensalem, S., & Huang, X. (2024). Safeguarding large language models: a survey. *Artificial Intelligence Review*, 58. https://doi.org/10.1007/s10462-025-11389-2

Sahoo, N., Saxena, A., Maharaj, K., Ahmad, A., Mishra, A., & Bhattacharyya, P. (2024). Addressing Bias and Hallucination in Large Language Models. **.

Huang, L., Yu, W., , W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2023). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Transactions on Information Systems*, 43, 1 - 55. https://doi.org/10.1145/3703155

Tonmoy, S., Zaman, S., Jain, V., Rani, A., Rawte, V., Chadha, A., & Das, A. (2024). A Comprehensive Survey of Hallucination Mitigation Techniques in Large Language Models. *ArXiv*, abs/2401.01313. https://doi.org/10.48550/arxiv.2401.01313

Abdelghafour, M., Mabrouk, M., & Taha, Z. (2024). Hallucination Mitigation Techniques in Large Language Models. *International Journal of Intelligent Computing and Information Sciences*. https://doi.org/10.21608/ijicis.2024.336135.1365

Wang, H., Fu, W., Tang, Y., Chen, Z., Huang, Y., Piao, J., Gao, C., Xu, F., Jiang, T., & Li, Y. (2025). A Survey on Responsible LLMs: Inherent Risk, Malicious Use, and Mitigation Strategy. *ArXiv*, abs/2501.09431. https://doi.org/10.48550/arxiv.2501.09431

Berberette, E., Hutchins, J., & Sadovnik, A. (2024). Redefining "Hallucination" in LLMs: Towards a psychology-informed framework for mitigating misinformation. *ArXiv*, abs/2402.01769. https://doi.org/10.48550/arxiv.2402.01769

Bhattacharya, R. (2024). Strategies to mitigate hallucinations in large language models. *Applied Marketing Analytics: The Peer-Reviewed Journal*. https://doi.org/10.69554/nxxb8234

Cossio, M. (2025). A comprehensive taxonomy of hallucinations in Large Language Models. *ArXiv*, abs/2508.01781. https://doi.org/10.48550/arxiv.2508.01781

Gumaan, E. (2025). Theoretical Foundations and Mitigation of Hallucination in Large Language Models. *ArXiv*, abs/2507.22915. https://doi.org/10.48550/arxiv.2507.22915

Darwish, A., Rashed, E., & Khoriba, G. (2025). Mitigating LLM Hallucinations Using a Multi-Agent Framework. *Information*. https://doi.org/10.3390/info16070517

Malmqvist, L. (2024). Sycophancy in Large Language Models: Causes and Mitigations. *ArXiv*, abs/2411.15287. https://doi.org/10.48550/arxiv.2411.15287

Ahmad, M., Yaramis, I., & Roy, T. (2023). Creating Trustworthy LLMs: Dealing with Hallucinations in Healthcare AI. *ArXiv*, abs/2311.01463. https://doi.org/10.20944/preprints202310.1662.v1

Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., Huang, X., Zhao, E., Zhang, Y., Chen, Y., Wang, L., Luu, A., Bi, W., Shi, F., & Shi, S. (2023). Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models. *ArXiv*, abs/2309.01219. https://doi.org/10.1162/coli.a.16

Asgari, E., Brown, N., Dubois, M., Khalil, S., Balloch, J., Yeung, J., & Pimenta, D. (2025). A framework to assess clinical safety and hallucination rates of LLMs for medical text summarisation. *NPJ Digital Medicine*, 8. https://doi.org/10.1038/s41746-025-01670-7

Luo, J., Li, T., Wu, D., Jenkin, M., Liu, S., & Dudek, G. (2024). Hallucination Detection and Hallucination Mitigation: An Investigation. *ArXiv*, abs/2401.08358. https://doi.org/10.48550/arxiv.2401.08358

Design and Evaluation of a Generative AI-Enhanced Serious Game ..., https://www.mdpi.com/2227-9709/13/1/16

Personalized Non-Player Characters: A Framework for Character ..., https://www.mdpi.com/2673-2688/6/5/93

Personalized Non-Player Characters: A Framework for Character-Consistent Dialogue Generation - ResearchGate, https://www.researchgate.net/publication/391445277_Personalized_Non-Player_Characters_A_Framework_for_Character-Consistent_Dialogue_Generation

Aligning LLMs for the Classroom with Knowledge- Based Retrieval: A Comparative RAG Study - arXiv, https://arxiv.org/html/2509.07846

Knowledge engineering information technology for ... - CEUR-WS.org, https://ceur-ws.org/Vol-4141/paper11.pdf

From RAG to Multi-Agent Systems: A Survey of Modern Approaches in LLM Development, https://www.preprints.org/manuscript/202502.0406

Speaking with the Past: Constructing AI-Generated Historical ... - MDPI, https://www.mdpi.com/2571-9408/8/9/387

Enhancing Scientific Communication and Institutional ... - Preprints.org, https://www.preprints.org/manuscript/202509.0180/v1/download

Creating Tabletop RPG Dialogues via Retrieval-Augmented ..., https://sol.sbc.org.br/index.php/sbgames/article/download/37366/37148/

AfricaNLP 2024 - Google, https://sites.google.com/view/africanlp2024/home

Benchmarking Vector, Graph and Hybrid Retrieval Augmented Generation (RAG) Pipelines for Open Radio Access Networks (ORAN) - ResearchGate, https://www.researchgate.net/publication/393477831_Benchmarking_Vector_Graph_and_Hybrid_Retrieval_Augmented_Generation_RAG_Pipelines_for_Open_Radio_Access_Networks_ORAN

Graph Rag Vs Vector RAG: Complete guide for Beginners - Chitika, https://www.chitika.com/graph-rag-vs-vector-rag/

GraphRAG: Improving RAG with Knowledge Graphs - Vellum AI, https://www.vellum.ai/blog/graphrag-improving-rag-with-knowledge-graphs

Fuzzy, Symbolic, and Contextual: Enhancing LLM Instruction via Cognitive Scaffolding, https://arxiv.org/html/2508.21204v2

Fuzzy, Symbolic, and Contextual: Enhancing LLM Instruction ... - arXiv, https://arxiv.org/pdf/2508.21204

(PDF) The Role of Memory in LLMs: Persistent Context for Smarter Conversations - ResearchGate, https://www.researchgate.net/publication/385808270_The_Role_of_Memory_in_LLMs_Persistent_Context_for_Smarter_Conversations

[2510.01375] Fine-tuning with RAG for Improving LLM Learning of New Skills - arXiv, https://arxiv.org/abs/2510.01375

[2506.05925] Small Models, Big Support: A Local LLM Framework for Teacher-Centric Content Creation and Assessment using RAG and CAG - arXiv, https://arxiv.org/abs/2506.05925

Enhancing User Experience in Games with Large ... - SciTePress, https://www.scitepress.org/Papers/2024/128546/128546.pdf

Takeaways from Applying LLM Capabilities to Multiple Conversational Avatars in a VR Pilot Study - arXiv, https://arxiv.org/html/2501.00168v2

(PDF) Exploring the Acceptance of Large Language Models as an Integrated Reading Tool: A UTAUT-Based Analysis - ResearchGate, https://www.researchgate.net/publication/397132566_Exploring_the_Acceptance_of_Large_Language_Models_as_an_Integrated_Reading_Tool_A_UTAUT-Based_Analysis

Language Understanding in the Human Machine Era 2025 Proceedings of 2nd LUHME Workshop Henrique Lopes Cardoso Rui Sousa-Silva Ma - ACL Anthology, https://aclanthology.org/2025.luhme-1.pdf

Generative Systems and Intelligent Tutoring Systems | springerprofessional.de, https://www.springerprofessional.de/generative-systems-and-intelligent-tutoring-systems/51286432

First Steps Towards Overhearing LLM Agents: A Case Study With Dungeons & Dragons Gameplay - arXiv, https://arxiv.org/html/2505.22809v2

RASE: Retrieval Augmented Story Engine Narration Control in game using AI - IJIRT, https://ijirt.org/publishedpaper/IJIRT184752_PAPER.pdf

Conversational Interactions with NPCs in LLM-Driven Gaming: Guidelines from a Content Analysis of Player Feedback | Request PDF - ResearchGate, https://www.researchgate.net/publication/378921351_Conversational_Interactions_

with_NPCs_in_LLM-
Driven_Gaming_Guidelines_from_a_Content_Analysis_of_Player_Feedback

The Many Challenges of Human-Like Agents in Virtual Game Environments. (2025). arXiv. https://arxiv.org/abs/2505.20011

Paduraru, C., Cernat, M., & Stefanescu, A. (2023). Conversational agents for simulation applications and video games. In Proceedings of the 18th International Conference on Software Technologies (ICSOFT 2023) (pp. 27–36). https://doi.org/10.5220/0012060500003538

Learning Human-Like RL Agents through Trajectory Optimization with Action Quantization - OpenReview, https://openreview.net/pdf/3075f74045ae309567070a48e9198a38e8a7b4f6.pdf

The Many Challenges of Human-Like Agents in Virtual Game Environments - arXiv, https://arxiv.org/html/2505.20011v1

Learning Human-Like RL Agents Through Trajectory Optimization With Action Quantization | Request PDF - ResearchGate, https://www.researchgate.net/publication/397780730_Learning_Human-Like_RL_Agents_Through_Trajectory_Optimization_With_Action_Quantization

(PDF) Conversational Agents for Simulation Applications and Video Games - ResearchGate, https://www.researchgate.net/publication/372321201_Conversational_Agents_for_Simulation_Applications_and_Video_Games

Large Language Models and Video Games: A Preliminary Scoping Review - arXiv, https://arxiv.org/html/2403.02613v1

Large Language Models and Video Games: A Preliminary Scoping Review - arXiv, https://arxiv.org/pdf/2403.02613

Alin STEFANESCU | Professor (Full) | PhD | University of Bucharest, Bucharest | Unibuc | Department of Computer Science | Research profile - ResearchGate, https://www.researchgate.net/profile/Alin-Stefanescu

Human-Centered Reinforcement Learning, https://ml.cmu.edu/research/phd-dissertation-pdfs/smilani_phd_mld_2025.pdf

Bullying the Machine: How Personas Increase LLM Vulnerability - ResearchGate, https://www.researchgate.net/publication/391877593_Bullying_the_Machine_How_Personas_Increase_LLM_Vulnerability

RICoTA: Red-teaming of In-the-wild Conversation with Test Attempts

Eujeong Choi, Younghun Jeong, Soomin Kim, Won Ik Cho

Independent Research Team “Annyeong! Luda”

arXiv:2501.17715v1 [cs.CL] 29 Jan 2025, https://arxiv.org/pdf/2501.17715?

Small Language Models for Curriculum-based Guidance - arXiv, https://arxiv.org/html/2510.02347v1

Aligning LLMs for the Classroom with Knowledge- Based Retrieval: A Comparative RAG Study - arXiv, https://arxiv.org/html/2509.07846

Building an Advanced Retrieval-Augmented Generation (RAG) Pipeline Using ChromaDB and Ollama | by Mr.MELVIN | Medium, https://medium.com/@mr.melvin.redwing/building-an-advanced-retrieval-augmented-generation-rag-pipeline-using-chromadb-and-ollama-deb8c879d5c9

Install GraphRAG Locally: vLLM & Ollama Setup Guide - Chitika, https://www.chitika.com/graphrag-local-install-setup-using-vllm-and-ollama/

List of available metrics - Ragas, https://docs.ragas.io/en/stable/concepts/metrics/available_metrics/

Retrieval-Augmented Reasoning with Lean Language Models - arXiv, https://arxiv.org/html/2508.11386v1

Paged Attention from First Principles: A View Inside vLLM | Hamza's Blog, https://hamzaelshafie.bearblog.dev/paged-attention-from-first-principles-a-view-inside-vllm/

vLLM Explained: How PagedAttention Makes LLMs Faster and Cheaper - DEV Community, https://dev.to/jaskirat_singh/vllm-explained-how-pagedattention-makes-llms-faster-and-cheaper-785

The Architecture Behind vLLM: How PagedAttention Improves Memory Utilization - Medium, https://medium.com/@mandeep0405/the-architecture-behind-vllm-how-pagedattention-improves-memory-utilization-2f9b25272110

Running LLM Locally with Ollama + RAG | by zacky syarief - Medium, https://zackydzacky.medium.com/running-llm-locally-with-ollama-rag-cb68ff31e838

Tested quantization on my 8GB potato laptop here's what actually breaks first - Reddit, https://www.reddit.com/r/LocalLLaMA/comments/1p8p844/tested_quantization_on_my_8gb_potato_laptop_heres/

Comparing Quantized Performance in Llama Models - LessWrong, https://www.lesswrong.com/posts/qmPXQbyYA66DuJbht/comparing-quantized-performance-in-llama-models

Hardware Suggestions for Local LLM with RAG and MCP for Nonprofit : r/ollama - Reddit, https://www.reddit.com/r/ollama/comments/1q4ov85/hardware_suggestions_for_local_llm_with_rag_and/

Enhancing RAG performance with smart chunking strategies - IBM Developer, https://developer.ibm.com/articles/awb-enhancing-rag-performance-chunking-strategies/

Comparative Evaluation of Advanced Chunking for Retrieval-Augmented Generation in Large Language Models for Clinical Decision Support - NIH, https://pmc.ncbi.nlm.nih.gov/articles/PMC12649634/

Mastering Document Chunking Strategies for Retrieval-Augmented Generation (RAG) | by Sahin Ahmed, Data Scientist | Medium, https://medium.com/@sahin.samia/mastering-document-chunking-strategies-for-retrieval-augmented-generation-rag-c9c16785efc7

Finding the Best Chunking Strategy for Accurate AI Responses | NVIDIA Technical Blog, https://developer.nvidia.com/blog/finding-the-best-chunking-strategy-for-accurate-ai-responses/

Small Models, Big Support: A Local LLM Framework for Teacher-Centric Content Creation and Assessment using RAG and CAG - ResearchGate, https://www.researchgate.net/publication/392514830_Small_Models_Big_Support_A_Local_LLM_Framework_for_Teacher-Centric_Content_Creation_and_Assessment_using_RAG_and_CAG

(PDF) Intelligent Tutoring for Law Courses: Design and Evaluation of ..., https://www.researchgate.net/publication/396447632_Intelligent_Tutoring_for_Law_Courses_Design_and_Evaluation_of_an_LLM-based_System

LPITutor: an LLM based personalized intelligent tutoring system ..., https://pmc.ncbi.nlm.nih.gov/articles/PMC12453719/

Training LLM-based Tutors to Improve Student Learning Outcomes in Dialogues - arXiv, https://arxiv.org/html/2503.06424v1

RAG Evaluation : A Comprehensive Guide | by Amanatullah - Medium, https://medium.com/@amanatulla1606/rag-evaluation-a-comprehensive-gui-b8d0aebaf86a

RAG Evaluation Using Ragas - Zilliz blog, https://zilliz.com/blog/rag-evaluation-using-ragas

Metrics - Ragas, https://docs.ragas.io/en/v0.1.21/concepts/metrics/

Evaluation Metrics for Retrieval-Augmented Generation (RAG) Systems - GeeksforGeeks, https://www.geeksforgeeks.org/nlp/evaluation-metrics-for-retrieval-augmented-generation-rag-systems/

RAG Evaluation Metrics: Assessing Answer Relevancy, Faithfulness, Contextual Relevancy, And More - Confident AI, https://www.confident-ai.com/blog/rag-evaluation-metrics-answer-relevancy-faithfulness-and-more

RAG Evaluation Metrics: Best Practices for Evaluating RAG Systems - Patronus AI, https://www.patronus.ai/llm-testing/rag-evaluation-metrics

Azure Small Language Models: Evaluating Phi-3, Llama 3, and Snowflake Arctic for Production, https://dev.to/jubinsoni/azure-small-language-models-evaluating-phi-3-llama-3-and-snowflake-arctic-for-production-35h6

Llama 3 vs. Mistral vs. Phi-3: Which Self-Hosted LLM Should You Choose for Business Tasks? - ForgeNEX, https://www.forgenex.com/en/blog/llama-3-vs-mistral-vs-phi-3-que-llm-autohospedado-elegir-para-tareas-de-negocio

Best Local LLMs for Offline Use in 2026: A Complete Comparison - IPRoyal.com, https://iproyal.com/blog/best-local-llms/

Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone, https://www.microsoft.com/en-us/research/publication/phi-3-technical-report-a-highly-capable-language-model-locally-on-your-phone/

Mistral vs Llama 3: Complete Comparison for Voice AI Applications - Vapi AI Blog, https://vapi.ai/blog/mistral-vs-llama-3

Local LLM Model Comparison Tool: Compare 2025's Best Open Source Models, https://localllm.in/blog/model-comparison-tool

Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone - arXiv, https://arxiv.org/html/2404.14219v1